

METODY BAYESOWSKIE  
W STATYSTYCE

---

prof. dr hab. W. Niemirow

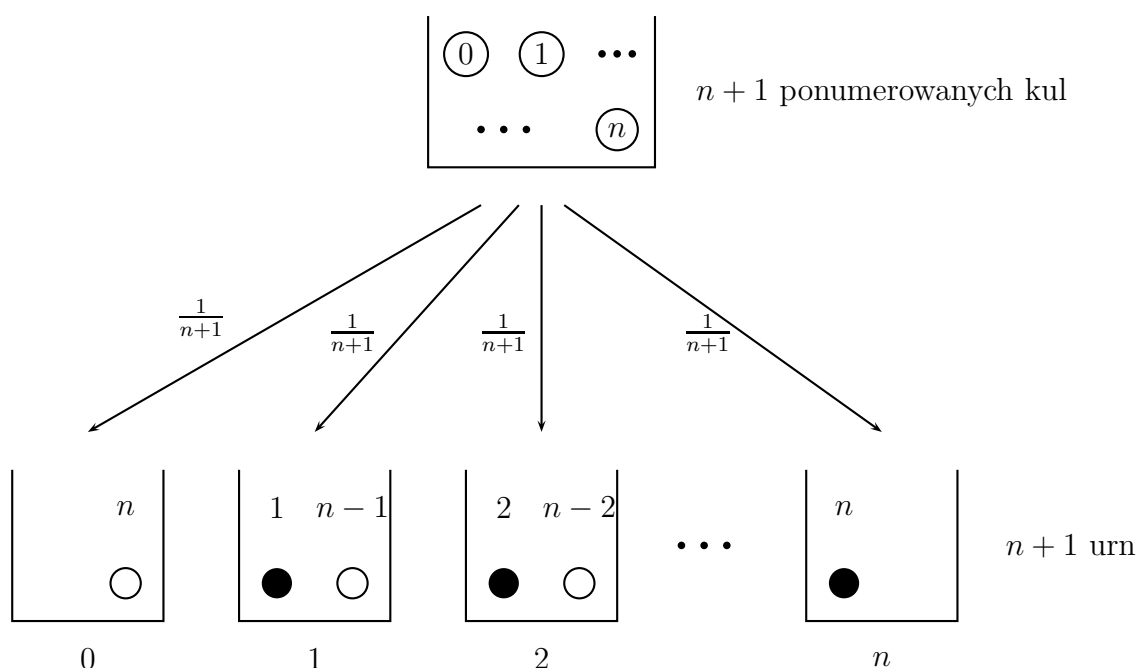
# Spis treści

1.	Klasyczny i bayesowski punkt widzenia w statystyce. Przykłady. . . . .	3
	Przykład Laplace’a . . . . .	3
2.	Podstawy probabilistyczne: warunkowe rozkłady prawdopodobieństwa, warunkowe wartości oczekiwane, twierdzenie Bayesa. . . . .	5
	Warunkowe rozkłady prawdopodobieństwa i wartości oczekiwane. . . . .	5
	Prawdopodobieństwo warunkowe i warunkowa wartość oczekiwana. . . . .	9
3.	Budowa statystycznych modeli bayesowskich. rozkłady <i>a priori</i> i <i>a posteriori</i> , warunkowa niezależność, statystyki dostateczne. . . . .	13
	Podstawowy model bayesowski. . . . .	15
	Dostateczność. . . . .	18
	Wykładnicze rodziny rozkładów prawdopodobieństwa. . . . .	20
	Typowe modele bayesowskie ze sprzężonymi rodzinami rozkładów. . . . .	23
4.	Funkcje straty, estymacja i predykcja bayesowska. . . . .	24
	Teoria decyzji statystycznych . . . . .	24
	Problemy klasyfikacji/dyskryminacji. . . . .	28
	Zmienne losowe w $\mathbb{R}^d$ . . . . .	31
5.	Wielowymiarowe rozkłady normalne. . . . .	31
	Różne funkcje straty w zadaniach estymacji. . . . .	35
	Testowanie hipotez statystycznych. . . . .	36
	Krzywa $(\alpha - \beta)$ Neymana – Pearsona. . . . .	38
	Testowanie hipotez złożonych w ujęciu bayesowskim. . . . .	39
	Zbiory (przedziały ufności) w ujęciu bayesowskim. . . . .	40
	Predykcja liniowa i liniowe modele bayesowskie. . . . .	41

# 1. Klasyczny i bayesowski punkt widzenia w statystyce. Przykłady.

05.10.2006r.

Przykład 1 (LAPLACE'A).



1. Wybieramy jedną z urn z jednakowym prawdopodobieństwem  $\frac{1}{n+1}$ .
2. Losujemy  $m$  razy ze zwracaniem (z/z) z wybranej uprzednio urny.
3. Losujemy jeszcze raz,  $(n+1)$ -szy raz z tejże urny.

Wiadomo, że w  $m$  losowaniach wybraliśmy same kule białe.

Jakie jest prawdopodobieństwo, że w kolejnym  $(n+1)$ -szym losowaniu też wyjdzie biała?

$U$  – numer urny wylosowanej w 1-szym etapie

$$\mathbb{P}(U = i) = \frac{1}{n+1} \quad i = 0, 1, \dots, n \quad (\text{rozkład } a \text{ priori})$$

$S$  – liczba kul białych w  $m$  losowaniach 2-go etapu

$$\mathbb{P}(S = k | U = i) = \binom{m}{k} \left(\frac{n-i}{n}\right)^k \left(\frac{i}{n}\right)^{m-k}$$

$X$  – liczba kul białych w  $(m+1)$ -szym losowaniu 3-go etapu

$$\mathbb{P}(X = 1 | U = i) = \frac{n-i}{n} \quad \mathbb{P}(X = 0 | U = i) = \frac{i}{n}$$

$$\mathbb{P}(X = 1 | S = m) = \frac{\mathbb{P}(X = 1, S = m)}{\mathbb{P}(S = m)} \quad (\text{Twierdzenie Bayesa})$$

$$\mathbb{P}(S = m|U = i) = \left(1 - \frac{i}{n}\right)^m$$

$$\mathbb{P}(S = m) = \sum_{i=0}^n \mathbb{P}(S = m|U = i)\mathbb{P}(U = i) = \sum_{i=0}^n \left(1 - \frac{i}{n}\right)^m \cdot \frac{1}{n+1}$$

$$\mathbb{P}(S = m, X = 1) = \sum_{i=0}^n \left(1 - \frac{i}{n}\right)^{m+1} \cdot \frac{1}{n+1}$$

Zatem:

$$\begin{aligned} \mathbb{P}(X = 1|S = m) &= \frac{\sum_{i=0}^n \left(1 - \frac{i}{n}\right)^{m+1} \cdot \frac{1}{n+1}}{\sum_{i=0}^n \left(1 - \frac{i}{n}\right)^m \cdot \frac{1}{n+1}} = \frac{\frac{1}{n} \sum_{j=0}^n \left(\frac{j}{n}\right)^{m+1}}{\frac{1}{n} \sum_{j=0}^n \left(\frac{j}{n}\right)^m} = \\ &= \frac{\frac{1}{n} \sum_{j=0}^n f\left(\frac{j}{n}\right)}{\frac{1}{n} \sum_{j=0}^n f\left(\frac{j}{n}\right)} \longrightarrow \frac{\int_0^1 x^{m+1} dx}{\int_0^1 x^m dx} = \frac{m+1}{m+2} \end{aligned}$$

✱ Rozkład prawdopodobieństwa definiuje się przy pomocy prawdopodobieństwa warunkowego.

✱ Subiektywna interpretacja prawdopodobieństwa na 1-szym etapie.

✱ Twierdzenie Bayesa.

✱ Nacisk na predykcję.

**Przykład 2** (KAPSLE TYMBARK).

60 kapsli                      50 różnych napisów  
200 dalszych kapsli       $X = ?$  różnych napisów



$\frac{1}{951}$  – prawdopodobieństwo wyboru urny

$S = 50$

$X = ?$

**Zadanie domowe 1.**

$\mathbb{P}(X = 190|U = 1000)$

**Algorytm 1.**

$U$	$S$	$X$
ukryte	znamy	chcemy przewidzieć

1. Losujemy z rozkładu  $U$ ,  $\mathbb{P}(U = i) = \frac{1}{951}$  (z rozkładu a priori)
2. Znając  $U$  losujemy z rozkładu  $S|U$

} rozkład a posteriori  
 $\mathbb{P}(U = i|S = 50)$

Jeśli  $S \neq 50$ , odrzuć (przejdź do 1)

Jeśli  $S = 50$ , wylosuj  $X|U$ , zapamiętaj

### Przykład 3.

Są 2 typy kierowców ostrożni –  $\mathcal{O}$  i ryzykanci –  $\mathcal{R}$ . Na jednego ostrożnego przypada 4 ryzykantów. Jeśli kierowca jest ostrożny, to powoduje szkodę w ciągu roku z prawdopodobieństwem 0.1. Jeśli kierowca jest ryzykantem, to powoduje szkodę w ciągu roku z prawdopodobieństwem 0.4.


1. Ubezpieczamy nowego kierowcę. Jakie jest prawdopodobieństwo, że zgłosi szkodę?
2. Kierowca zgłosił szkodę w 1-szym roku ubezpieczenia. Jakie jest prawdopodobieństwo, że jest typu  $\mathcal{O}$ ?
3. Kierowca zgłosił szkodę w 1-szym roku. Jakie jest prawdopodobieństwo, że zgłosi szkodę i w 2-gim roku?
4. Kierowca zgłosił szkody w dwóch kolejnych latach. Jakie jest prawdopodobieństwo, że zgłosi szkodę i w trzecim roku?

## 2. Podstawy probabilistyczne: warunkowe rozkłady prawdopodobieństwa, warunkowe wartości oczekiwane, twierdzenie Bayesa.

19.10.2006r.

### Warunkowe rozkłady prawdopodobieństwa i wartości oczekiwane.

GĘSTOŚĆ ROZKŁADU PRAWDOPODOBIEŃSTWA:



$(\Omega, \mathcal{F}, \mathbb{P})$  – przestrzeń probabilistyczna

$X : \Omega \longrightarrow \mathcal{X}$  – zmienna losowa o wartościach w  $\mathcal{X}$


$$\forall_{A \in \mathcal{A}} \quad X^{-1}(A) = \{\omega \in \Omega; X(\omega) \in A\} = \{X \in A\} \in \mathcal{F}$$

Rozkład prawdopodobieństwa zmiennej losowej  $X$

$$\mathcal{A} \ni A \longmapsto \mathbb{P}(X \in A) = \mathbb{P}_X(A)$$

$$\mathbb{P}_X : \mathcal{A} \longrightarrow [0, 1]$$

$$\mathbb{P} : \mathcal{F} \rightarrow [0, 1]$$



**Definicja 1.**

Rozkład prawdopodobieństwa zmiennej losowej  $X$  ma gęstość  $f = f_X : \mathcal{X} \longrightarrow \mathbb{R}_+$ , jeśli:

$$\forall_{A \in \mathcal{A}} \quad \mathbb{P}(X \in A) = \int_A f(x) \mu(dx) = \int_A f d\mu$$

**Przykład 4.**

$\mathcal{X} = \mathbb{R}^d$ ,  $\mu$  – miara Lebesgue’a,  $\mathcal{A}$  –  $\sigma$  - ciało borelowskie

$$\int_A f(x) \mu(dx) = \int_A f(x) dx$$

**Przykład 5.**

$\mathcal{X}$  – przeliczalny, lub skończony,

$$\mu \text{ – miara licząca, tzn.: } \mu(A) = \begin{cases} \#A & \text{jeśli } A \text{ jest skończony} \\ \infty & \text{w p.p.} \end{cases}$$


$$\int_A f(x) \mu(dx) = \sum_{x \in A} f(x)$$

} przestrzeń dyskretna

$$\left. \begin{array}{l} (\mathcal{X}, \mathcal{A}, \mu) \\ (\mathcal{Y}, \mathcal{B}, \nu) \end{array} \right\} \text{przestrzeń z miarami } \sigma \text{ - skończonymi}$$

$$(\mathcal{X} \times \mathcal{Y}, \mathcal{A} \otimes \mathcal{B}, \mu \otimes \nu)$$

$$\mathcal{A} \otimes \mathcal{B} = \sigma(\{A \times B; \quad A \in \mathcal{A}, \quad B \in \mathcal{B}\})$$



$$\mu \otimes \nu(A \times B) = \mu(A) \cdot \nu(B)$$

### Umowa 1.

$$f : \mathcal{X} \times \mathcal{Y} \longrightarrow \mathbb{R}$$

$$\iint_{\mathcal{X} \times \mathcal{Y}} f(x, y) \mu \otimes \nu(dx, dy) \stackrel{tw. \text{ Fubiniego}}{=} \int_{\mathcal{Y}} \int_{\mathcal{X}} f(x, y) \mu(dx) \nu(dy) = \int_{\mathcal{Y}} \int_{\mathcal{X}} f(x, y) dx dy$$

$(X, Y) : \Omega \longrightarrow \mathcal{X} \times \mathcal{Y}$  – zmienna losowa, czyli odwzorowanie mierzalne względem  $\sigma$  - ciała produktowego

### Definicja 2.

Rozkład prawdopodobieństwa zmiennej losowej  $(X, Y)$  ma gęstość łączną  $f = f_{X,Y}$ ,  $\mathcal{X} \times \mathcal{Y} \longrightarrow \mathbb{R}_+$ , jeśli:

$$\forall C \in \mathcal{A} \otimes \mathcal{B} \quad \iint_C f(x, y) \mu(dx) \nu(dy) = \mathbb{P}((X, Y) \in C)$$

### Uwaga 1.

Wystarczy jeśli

$$\int_B \int_A f(x, y) \mu(dx) \nu(dy) = \mathbb{P}(X \in A, Y \in B) \quad \forall A \in \mathcal{A} \quad \forall B \in \mathcal{B}$$

### Uwaga 2.

Rozkład brzegowy zmiennej losowej  $X$  ma gęstość

$$f_X(x) = \int_Y f(x, y) \nu(dy)$$

$$\mathbb{P}(X \in A) \stackrel{tw. \text{ Fubiniego}}{=} \int_A f_X(x) \mu(dx)$$

### Uwaga 3.

Jeżeli  $\mathcal{X}$  i  $\mathcal{Y}$  – dyskretne, to

$$f_X(x) = \mathbb{P}(X = x) = \sum_y f(x, y)$$

$$f(x, y) = \mathbb{P}(X = x, Y = y)$$

**Definicja 3.**

Założmy, że:  $(X, Y) : \Omega \longrightarrow \mathcal{X} \times \mathcal{Y}$  ma gęstość łączną  $f$ .

Gęstość warunkową określamy wzorem:

$$f(y|x) = f_{Y|X}(y|x) = \begin{cases} \frac{f(x,y)}{f_X(x)} & \text{jeśli } f_X(x) > 0 \\ 0 & \text{w p.p.} \end{cases}$$

**Uwaga 4.**

Jeżeli  $\mathcal{X}$  i  $\mathcal{Y}$  dyskretne, to:

$$f(y|x) = \frac{\mathbb{P}(X = x, Y = y)}{\mathbb{P}(X = x)} = \mathbb{P}(Y = y|X = x)$$

**Definicja 4.**

PRAWDOPODOBIENSTWO WARUNKOWE

$$\mathbb{P}(Y \in B|X = x) = \int_B f(y|x)\nu(dy) \stackrel{\text{ozn.}}{=} p(B, x)$$

1. Dla dowolnego  $x$ , z wyjątkiem zbioru  $N = \{x; f(x) = 0\}$

$p(\cdot, x)$  jest miarą probabilistyczną na  $(\mathcal{Y}, \mathcal{B})$

Jeżeli  $f_X(x) > 0$ , to  $\int_{\mathcal{Y}} f(y|x)\nu(dy) = 1$

2. Dla dowolnego  $B \in \mathcal{B}$

$p(\mathcal{B}, \cdot) : (\mathcal{X}, \mathcal{A}) \longrightarrow \mathbb{R}$  – jest mierzalne

**Uwaga 5.**


Jeżeli  $\mathcal{X}$  jest przestrzenią dyskretną, to:

$$\mathbb{P}(Y \in B|X = x) = \frac{\mathbb{P}(Y \in B, X = x)}{\mathbb{P}(X = x)}$$

**Przykład 6.**

$U, V$  – niezależne o rozkładzie  $\mathcal{U}(0, 1)$

$$f_{U,V}(u, v) = 1 \quad \text{dla } (u, v) \in [0, 1]^2$$

**Przykład 7.**


Niech:  $X = \min(U, V)$  i  $Y = \max(U, V)$

$$f_{X,Y}(x, y) = f(x, y) = \begin{cases} 2 & 0 \leq x \leq y \leq 1 \\ 0 & \text{w p.p.} \end{cases}$$

$$X, Y \in C \Leftrightarrow (U, V) \in C \quad \text{lub} \quad (U, V) \in C$$

$$f_X(x) = \int_x^1 f(x, y)dy = \int_x^1 2dy = 2(1 - x)$$


$$f(y|x) = \frac{f(x,y)}{f_X(x)} = \begin{cases} \frac{1}{1-x} & 0 \leq x \leq y \leq 1 \\ 0 & \text{w p.p.} \end{cases}$$





$f(y|x)$  jest gęstością rozkładu  $\mathcal{U}(x, 1)$

$$\mathbb{P}\left(Y > \frac{9}{10} | X = x\right) = \int_{\frac{9}{10}}^1 f(y, x) dy = \begin{cases} 1 & \text{dla } x > \frac{9}{10} \\ \frac{1}{10} \cdot \frac{1}{1-x} & \text{dla } x \leq \frac{9}{10} \end{cases}$$



### Definicja 5.

WARUNKOWA WARTOŚĆ OCZEKIWANA

$$\mathbb{E}(Y|X = x) = \int_{\mathcal{Y}} y f(y|x) dy$$

### Uwaga 6.

Bardziej ogólnie, jeśli  $h : \mathcal{Y} \longrightarrow \mathbb{R}$  lub  $\mathbb{R}^d$

$$\mathbb{E}(h(Y)|X = x) = \int_{\mathcal{Y}} h(y) f(y|x) dy$$

### Uwaga 7.

Rozpatrujemy warunkową wartość oczekiwaną jako funkcję  $x$

$$\mathbb{E}(h(Y)|X = x) = r(x) \quad r : \mathcal{X} \longrightarrow \mathbb{R} \quad \text{lub} \quad \mathbb{R}^d$$

25.10.2006r.

## Prawdopodobieństwo warunkowe i warunkowa wartość oczekiwana.

$X, Y : \Omega \longrightarrow \mathcal{X} \times \mathcal{Y}$

$f(x, y)$  – gęstość względem  $\mu \otimes \nu$ ,  $\left( \mu, \nu \text{ – albo miary Lebesgue'a albo miary liczące} \right)$   
konwencja:  $\mu(dx) = dx, \quad \nu(dy) = dy$

$$f(y|x) = \frac{f(x, y)}{f_X(x)}$$

$$\mathbb{P}(Y \in B | X = x) \stackrel{\text{df}}{=} \int_B f(y|x) dy$$

### Przykład 8.

$U_1, U_2$  – niezależne  $\sim \mathcal{U}(0, 1)$

$X = \min(U_1, U_2), \quad Y = \max(U_1, U_2)$

$$f(x, y) = \begin{cases} 2, & 0 \leq x \leq y \leq 1 \\ 0, & \text{w p. p.} \end{cases}$$

Dla ustalonego  $x \in (0, 1)$

$$f(y|x) = \begin{cases} \frac{1}{1-x}, & y \in (x, 1) \\ 0, & \text{w p. p.} \end{cases}$$

Rozkład warunkowy przy danym  $X = x$  jest  $\mathcal{U}(x, 1)$

## WZÓR NA PRAWDOPODOBIENSTWO CAŁKOWITE

$$\mathbb{P}(Y \in B) = \int_{\mathcal{X}} \mathbb{P}(Y \in B|X = x) f_X(x) dx$$

**Dowód.**

$$\begin{aligned} \mathbb{P}(Y \in B) &= \int_B f_Y(y) dy = \int_B \int_{\mathcal{X}} f(x, y) dx dy = \int_B \int_{\mathcal{X}} f(y|x) f_X(x) dx dy \\ &= \int_{\mathcal{X}} \underbrace{\int_B f(y|x) dy}_{f_Y(y)} f_X(x) dx \end{aligned}$$

□

## WZÓR BAYESA

$$f(x|y) = \frac{f(y|x)f_X(x)}{f_Y(y)}$$

**Dowód.**

$$f(x|y) = \frac{f(x, y)}{f_Y(y)}$$

□

Jeżeli  $\mu$  i  $\nu$  – miary liczące

$$f(x, y) = \mathbb{P}(X = x, Y = y), \quad f_X(x) = \mathbb{P}(X = x), \quad f(y|x) = \mathbb{P}(Y = y|X = x)$$

$$\mathbb{P}(Y \in B) = \sum_x \mathbb{P}(Y \in B|X = x) \mathbb{P}(X = x)$$

## WZÓR BAYESA DLA MIAR LICZĄCYCH

$$\mathbb{P}(X = x|Y = y) = \frac{\mathbb{P}(Y = y|X = x) \mathbb{P}(X = x)}{\mathbb{P}(Y = y)}$$

**Definicja 6.**

$$\mathbb{E}(Y|X = x) = \int_{\mathcal{Y}} y f(y|x) dy = r(y), \quad r : \mathcal{X} \longrightarrow \mathcal{Y}$$

## WZÓR NA PRAWDOPODOBIENSTWO CAŁKOWITE

$$\mathbb{E} Y = \int_{\mathcal{X}} \underbrace{\mathbb{E}(Y|X = x)}_{f_Y(y)} f_X(x) dx$$

**Dowód.**

$$\begin{aligned} \mathbb{E} Y &= \int_{\mathcal{Y}} y f_Y(y) dy = \int_{\mathcal{Y}} y \int_{\mathcal{X}} f(x, y) dx dy = \int_{\mathcal{Y}} y \int_{\mathcal{X}} f(y|x) f_X(x) dx dy \\ &= \int_{\mathcal{X}} \underbrace{\int_{\mathcal{Y}} y f(y|x) dy}_{f_Y(y)} f_X(x) dx \end{aligned}$$

$$\mathbb{E} Y = \int_{\mathcal{X}} \mathbb{E}(Y|X = x) f_X(x) dx = \int_{\mathcal{X}} r(x) f_X(x) dx = \mathbb{E} r(X)$$

□

**Definicja 7.**

Zmienną losową  $r(X)$  oznaczamy  $\mathbb{E}(Y|X)$

$$\begin{array}{ccccc} \Omega & \xrightarrow{X} & \mathcal{X} & \xrightarrow{r} & \mathcal{Y} \\ & & r(X) = r \circ X & & \\ & & r(X)(\omega) = r(X(\omega)) & & \end{array}$$

**Wniosek 1** (WZÓR NA PRAWDOPODOBIENSTWO CAŁKOWITE).

$$\mathbb{E} Y = \mathbb{E} \mathbb{E}(Y|X)$$

WŁASNOŚCI WARUNKOWEJ WARTOŚCI OCZEKIWANEJ –  $\mathbb{E}(Y|X)$

0.  $\mathbb{E}(Y|X)$  jest funkcją zmiennej losowej  $X$

1.  $\mathbb{E}(Y_1 + Y_2|X) = \mathbb{E}(Y_1|X) + \mathbb{E}(Y_2|X)$

2.  $\mathbb{E}(aY|X) = a\mathbb{E}(Y|X)$

3. Jeżeli  $X$  i  $Y$  są niezależne, to  $\mathbb{E}(Y|X) = \mathbb{E} Y$

$$\begin{aligned} f(x, y) &= f_X(x)f_Y(y) \\ f(y|x) &= f_Y(y) \\ \mathbb{E}(Y|X = x) &= \mathbb{E} Y \end{aligned}$$

4.  $\mathbb{E}(h(Y)|X = x) = \int_{\mathcal{Y}} h(y)f(y|x)dy$ ,  $h : \mathcal{Y} \longrightarrow R$

5.  $\mathbb{E}(h(Y, X)|X = x) = \int_{\mathcal{Y}} h(y, x)f(y|x)dy$ ,  $h : \mathcal{Y} \times \mathcal{X} \longrightarrow \mathbb{R}$

6.  $\mathbb{E}(h(Y)g(X)|X = x) = g(x)\mathbb{E}(h(Y)|X = x)$

$$\mathbb{E}(h(Y)g(X)|X) = g(X)\mathbb{E}(h(Y)|X)$$

7.  $\mathbb{E} \mathbb{E}(Y|X) = \mathbb{E} Y$

**Definicja 8.**

$$Var(Y|X = x) = \int_{\mathcal{Y}} (y - r(x))^2 f(y|x)dy \stackrel{\text{ozn.}}{=} v(x)$$

**Definicja 9.**

Zmienną losową  $v(X)$  ozn.  $Var(Y|X)$

$$Var(Y|X) = \mathbb{E}[(Y - \mathbb{E}(Y|X))^2|X] = \mathbb{E}(Y^2|X) - \mathbb{E}(Y|X)^2$$

Ponieważ:

$$\begin{aligned} Var(Y|X) &= \mathbb{E}[(Y - \mathbb{E}(Y|X))^2|X] = \mathbb{E}[Y^2 - 2Y\mathbb{E}(Y|X) + \mathbb{E}(Y|X)^2|X] \\ &= \mathbb{E}(Y^2|X) - 2\mathbb{E}(Y|X)\mathbb{E}(Y|X) + \mathbb{E}(Y|X)^2 = \mathbb{E}(Y^2|X) - \mathbb{E}(Y|X)^2 \end{aligned}$$

**Twierdzenie 1.**

$$Var(Y) = \mathbb{E} Var(Y|X) + Var \mathbb{E}(Y|X)$$


**Dowód.**  $Var(Y) = \mathbb{E} v(X) + Var r(X)$ ,  $m = \mathbb{E} Y = \mathbb{E} r(X)$

$$\begin{aligned}
 Var(Y) &= \int_{\mathcal{Y}} (y - m)^2 f_Y(y) dy = \int_{\mathcal{X}} \int_{\mathcal{Y}} (y - m)^2 f(y|x) f_X(x) dy dx \\
 &= \int_{\mathcal{X}} \int_{\mathcal{Y}} (y - r(x) + r(x) - m)^2 f(y|x) dy f_X(x) dx \\
 &= \int_{\mathcal{X}} \underbrace{\int_{\mathcal{Y}} (y - r(x))^2 f(y|x) dy f_X(x) dx}_{v(x)} + \int_{\mathcal{X}} (r(x) - m)^2 \underbrace{\int_{\mathcal{Y}} f(y|x) dy f_X(x) dx}_1 dx \\
 &= \int_{\mathcal{X}} v(x) f_X(x) dx + Var r(X) = \mathbb{E} v(X) + Var r(X)
 \end{aligned}$$

$$\int_{\mathcal{X}} \int_{\mathcal{Y}} (y - r(x))(r(x) - m) f(y|x) dy f_X(x) dx = \int_{\mathcal{X}} (r(x) - m) \underbrace{\int_{\mathcal{Y}} (y - r(x)) f(y|x) dy f_X(x) dx}_0$$

□


**Przykład 9.**



$$\begin{aligned}
 Var(Y|X=0) &= \frac{2}{9} & Var(Y|X) &= \frac{2}{9} \\
 Var(Y|X=1) &= \frac{2}{9} & \mathbb{E} Var(Y|X) &= \frac{2}{9} \\
 \mathbb{E}(Y|X=0) &= \frac{1}{3} \\
 \mathbb{E}(Y|X=1) &= \frac{2}{3} & Var \mathbb{E}(Y|X) &= \frac{1}{4.9}
 \end{aligned}$$

26.10.2006r.

**Specyfikacja rozkładu łącznego przez rozkłady warunkowe.**



**Przykład 10.**

$N$  – liczba rozszerzeń.  $N \sim Poiss(\lambda)$ . Każde rozszerzenie jest uwzględniane z prawdopodobieństwem  $p$  lub odrzucane z prawdopodobieństwem  $q = 1 - p$ , niezależnie dla każdego rozszerzenia.

$K$  – liczba rozszerzeń uwzględnionych.  $\mathbb{P}(K = k) = „?”$

$$\mathbb{P}(K = k | N = n) = \binom{n}{k} p^k q^{n-k}$$

$$\begin{aligned} \mathbb{P}(K = k) &= \sum_{n=k}^{\infty} \mathbb{P}(K = k | N = n) \mathbb{P}(N = n) = \sum_{n=k}^{\infty} \binom{n}{k} p^k q^{n-k} e^{-\lambda} \frac{\lambda^n}{n!} \\ &= e^{-\lambda} p^k \sum_{n=k}^{\infty} \frac{n!}{k!(n-k)!} q^{n-k} \frac{\lambda^n}{n!} = e^{-\lambda} \frac{p^k}{k!} \sum_{n=k}^{\infty} \frac{\lambda^{n-k} \lambda^k}{(n-k)!} q^{n-k} \\ &\stackrel{i=n-k}{=} e^{-\lambda} \frac{(\lambda p)^k}{k!} \sum_{i=0}^{\infty} \frac{(\lambda q)^i}{i!} = e^{-\lambda} \frac{(\lambda p)^k}{k!} e^{\lambda q} = e^{-\lambda p} \frac{(\lambda p)^k}{k!}, \quad K \sim \text{Poiiss}(\lambda p) \end{aligned}$$

### 3. Budowa statystycznych modeli bayesowskich. rozkłady *a priori* i *a posteriori*, warunkowa niezależność, statystyki dostateczne.

#### Definicja 10.

Załóżmy, że  $X, Y_1, Y_2$  mają łączną gęstość na  $\mathcal{X} \times \mathcal{Y}_1 \times \mathcal{Y}_2$ . Mówimy, że  $Y_1$  i  $Y_2$  są WARUNKOWO NIEZALEŻNE przy danym  $X$  jeśli

$$\forall_{x, y_1, y_2} \quad f(y_1, y_2 | x) = f(y_1 | x) f(y_2 | x) \quad \text{ozn. } Y_1 Y_2 \perp\!\!\!\perp X$$

#### Wniosek 2.

Jeśli  $Y_1 Y_2 \perp\!\!\!\perp X$ , to  $f(y_2 | x, y_1) = f(y_2 | x)$

#### Dowód.

$$f(y_2 | x, y_1) = \frac{f(x, y_1, y_2)}{f(x, y_1)} = \frac{f(y_1, y_2 | x) f(x)}{f(y_1 | x) f(x)} = \frac{f(y_1 | x) f(y_2 | x) f(x)}{f(y_1 | x) f(x)} = f(y_2 | x)$$

□

UOGÓLNIENIE:  $(Y_1, \dots, Y_n) \perp\!\!\!\perp X$

$$f(y_1, \dots, y_n | x) = \prod_{i=1}^n f(y_i | x)$$

I Rzucamy monetę.

II Losujemy kolejno z tej samej, wybranej urny z/z kule  $Y_1, \dots, Y_n$

PODSTAWOWY MODEL STATYSTYKI BAYESOWSKIEJ.

$\mathcal{Y}$  – przestrzeń obserwacji

$Y$  – zmienna losowa interpretowana jako „obserwacja”

Rodzina rozkładów prawdopodobieństwa na przestrzeni  $\mathcal{Y}$  o gęstościach  $f_\theta(y)$  (względem ustalonej miary  $\nu$  na  $\sigma$ -ciele  $\mathcal{A}$ )


$\theta$  – parametr rozkładu prawdopodobieństwa,  $\theta \in \mathcal{P}$  – przestrzeń parametrów

$(\mathcal{Y}, \mathcal{A}, \{f_\theta \nu : \theta \in \mathcal{P}\})$  – przestrzeń statystyczna

gdzie  $f_\theta \nu$  oznacza miarę probabilistyczną o gęstości  $f_\theta$  względem  $\nu$

Jeżeli na zbiorze  $\mathcal{P}$  mamy  $\sigma$  - ciało  $\mathcal{C}$  i miara probabilistyczna  $\pi\mu$  (o gęstości  $\pi$  względem miary  $\mu$  na  $\mathcal{P}$ )

$(\mathcal{Y}, \mathcal{A}, \{f_\theta \nu : \theta \in \mathcal{P}\}, \mathcal{C}, \pi\mu) = (\mathcal{Y}, \{f_\theta : \theta \in \mathcal{P}\}, \pi)$  – bayesowska przestrzeń statystyczna



Łączny rozkład prawdopodobieństwa na  $\mathcal{P} \times \mathcal{Y}$  ma gęstość

$$f(\theta, y) \stackrel{\text{df}}{=} \pi(\theta) f_\theta(y)$$

Możemy traktować parametr jako zmienną losową  $\Theta$  o rozkładzie prawdopodobieństwa  $\pi$

Gęstość warunkowa

$$f(y|\theta) = \frac{f(\theta, y)}{\pi(\theta)} = f_\theta(y)$$

#### TERMINOLOGIA

$\pi$  – rozkład *a priori*

$f(y|\theta) = f_\theta(y)$  – wiarygodność

Rozkład *a posteriori*

$$\pi_y(\theta) = f(\theta|y) = \frac{f(y|\theta)\pi(\theta)}{f(y)}, \quad \text{gdzie } f(y) = \int_{\mathcal{P}} f(y|\theta)\pi(\theta)d\theta$$

#### Przykład 11.

$\mathcal{Y} = \{0, 1, \dots, n\}$  – przestrzeń obserwacji

$\mathcal{P} = [0, 1]$  – przestrzeń parametrów

$Y$  – liczba sukcesów w schemacie Bernoulliego z prawdopodobieństwem sukcesu  $\theta$  i liczbą doświadczeń  $n$

$$\mathbb{P}(Y = k|\theta) = \binom{n}{k} \theta^k (1 - \theta)^{n-k} = f(k|\theta)$$


$\pi$  – rozkład jednostajny  $\mathcal{U}(0, 1)$

$\pi(\theta) \equiv 1$

$$f(k) = \int_0^1 \binom{n}{k} \theta^k (1 - \theta)^{n-k} d\theta = \binom{n}{k} \int_0^1 \theta^k (1 - \theta)^{n-k} d\theta = \binom{n}{k} \frac{\Gamma(k+1)\Gamma(n-k+1)}{\Gamma(n+2)} = \binom{n}{k} \frac{k!(n-k)!}{(n+1)!}$$

Stąd

$$\begin{aligned}\pi_k(\theta) &= \frac{f(k|\theta)\pi(\theta)}{f(k)} = \frac{\binom{n}{k}\theta^k(1-\theta)^{n-k}}{\binom{n}{k}\frac{k!(n-k)!}{(n+1)!}} = \frac{(n+1)!}{k!(n-k)!}\theta^k(1-\theta)^{n-k} \\ &= (n+1)\binom{n}{k}\theta^k(1-\theta)^{n-k} = \text{const} \cdot \theta^k(1-\theta)^{n-k}\end{aligned}$$



Szukamy max gęstości

$$\begin{aligned}\log \pi_k(\theta) &= \text{const} + k \log \theta + (n-k) \log(1-\theta) \\ (\log \pi_k(\theta))' &= k \cdot \frac{1}{\theta} + (n-k) \cdot \frac{1}{1-\theta} \cdot (-1) \\ k \cdot \frac{1}{\theta} + (n-k) \cdot \frac{1}{1-\theta} \cdot (-1) &= 0 \\ k \cdot \frac{1}{\theta} &= (n-k) \cdot \frac{1}{1-\theta} \\ k(1-\theta) &= (n-k)\theta \\ (n-k+k)\theta &= k \\ \theta &= \frac{k}{n}\end{aligned}$$

### Definicja 11.

Mówimy, że  $\Theta \sim \text{Beta}(\alpha, \beta)$ , jeśli ma gęstość

$$\pi(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1}(1-\theta)^{\beta-1}, \quad \text{dla } 0 < \theta < 1, \quad \alpha > 0, \quad \beta > 0$$

$$\text{Beta}(1, 1) \sim U(0, 1)$$

$$\text{Beta}(2, 1) \sim 2\theta$$

$$\text{Beta}(1, 2) \sim 2(1-\theta)$$

02.11.2006r.

### Podstawowy model bayesowski.

$$\begin{array}{ll} \text{Przestrzeń} & \mathcal{P} \times \mathcal{Y} \\ \mu & \nu \end{array}$$

$$\Theta \quad Y$$

$$f(\theta; y) \stackrel{df}{=} \pi(\theta)f(y|\theta)$$

gdzie  $\pi(\theta)$  – rozkład *a priori*, (gęstość względem miary  $\mu$ )  
 $f(y|\theta)$  – wiarygodność, (gęstość względem miary  $\nu$ )

Zwykle (niekoniecznie)  $Y = (Y_1, \dots, Y_n)$ ,  $Y_1, \dots, Y_n$  – są warunkowo niezależne przy danym  $\Theta = \theta$

$$f(\theta; y_1, \dots, y_n) = \pi(\theta) \prod_i f(y_i|\theta)$$

$$\mathcal{Y} = \mathcal{Y}_1^n$$

ROZKŁAD BRZEGOWY OBSERWACJI

$$f(y) = \int_{\mathcal{P}} f(\theta, y) d\theta$$

$$f(y_1, \dots, y_n) = \int_{\mathcal{P}} f(\theta, y_1, \dots, y_n) d\theta$$

ROZKŁAD *a posteriori*

$$\pi_y(\theta) = f(\theta|y) = \frac{\pi(\theta)f(y|\theta)}{f(y)} \propto \pi(\theta)f(\theta)$$

**Definicja 12.**

$$g_1(\theta) \propto g_2(\theta) \quad \Leftrightarrow \quad \exists_{c \neq 0} \quad g_1(\theta) = cg_2(\theta)$$

Czasami  $\mathcal{Y} = \mathcal{Y}_1^{n+1}$ ,  $\Theta, Y_1, \dots, Y_n, Y_{n+1}$

gdzie  $\Theta$  – nieobserwowana zmienna losowa; („wymyślona”)  
 $Y_1, \dots, Y_n$  – obserwacje  
 $Y_{n+1}$  – nieobserwowana zmienna losowa; (nie znamy jej, ale poznamy)

$$f(y) = \int f(y|\theta)\pi(\theta)d\theta$$

$$f(y_2|y_1) = \int f(y_2|\theta, y_1)f(\theta|y_1)d\theta$$

ROZKŁAD PREDYKCYJNY

$$f(y_{n+1}|y_1, \dots, y_n) = \int f(y_{n+1}|y_1, \dots, y_n, \theta)f(\theta|y_1, \dots, y_n)d\theta = \int f(y_{n+1}|\theta)\pi_{y_1, \dots, y_n}(\theta)d\theta$$

**Przykład 12.**

BERNOULLI/BETA  $\mathcal{P} = [0, 1]$ ,  $\mathcal{Y} = \{0, 1\}^{n+1}$

Schemat Bernoulliego z nieznanym prawdopodobieństwem sukcesu  $\theta$

$Y_1, \dots, Y_n, Y_{n+1}$

$$\begin{cases} \mathbb{P}_\theta(Y = 1) = \theta = \mathbb{P}(Y = 1|\theta) = f(1|\theta) \\ \mathbb{P}_\theta(Y = 0) = 1 - \theta = \mathbb{P}(Y = 0|\theta) = f(0|\theta) \end{cases}$$



$$f(y|\theta) = \theta^y(1-\theta)^{1-y}$$

$$f(y_1, \dots, y_n|\theta) = \mathbb{P}_\theta(Y_1 = y_1, \dots, Y_n = y_n) = \theta^{\sum y_i} (1-\theta)^{n-\sum y_i} - \text{rozkład Bernoulliego}$$

Rozkład *a priori*  $\Theta \sim \mathcal{Beta}(\alpha, \beta)$

$$\pi(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1} \propto \theta^{\alpha-1} (1-\theta)^{\beta-1}$$

ROZKŁAD *a posteriori*

$$\pi_{y_1, \dots, y_n}(\theta) \propto \theta^{\alpha-1} (1-\theta)^{\beta-1} \theta^{\sum y_i} (1-\theta)^{n-\sum y_i} = \theta^{\alpha+\sum y_i-1} (1-\theta)^{\beta+n-\sum y_i-1} \sim \mathcal{Beta}(\alpha+\sum y_i, \beta+n-\sum y_i)$$

$$\mathbb{E}(\Theta|y_1, \dots, y_n) = \frac{\alpha + \sum y_i}{\alpha + \beta + n} = \frac{\alpha}{\alpha + \beta} \cdot \frac{\alpha + \beta}{\alpha + \beta + n} + \frac{\sum y_i}{n} \cdot \frac{n}{\alpha + \beta + n} = (1-z) \frac{\alpha}{\alpha + \beta} + \bar{y} \cdot z$$

gdzie  $z = \frac{n}{\alpha + \beta + n}$

dla  $n \rightarrow \infty \quad z \rightarrow 1$

$\frac{\alpha}{\alpha + \beta}$  – średnia *a priori*

$\bar{y}$  – średnia z obserwacji

ROZKŁAD BRZEGOWY

$$\begin{aligned} f(y_1, \dots, y_n) &= \mathbb{P}(Y_1 = y_1, \dots, Y_n = y_n) = \int_0^1 \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha+\sum y_i-1} (1-\theta)^{\beta+n-\sum y_i-1} d\theta \\ &= \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \cdot \frac{\Gamma(\alpha + \sum y_i) \Gamma(\beta + n - \sum y_i)}{\Gamma(\alpha + \beta + n)} = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \cdot \frac{\Gamma(\alpha + s) \Gamma(\beta + n - s)}{\Gamma(\alpha + \beta + n)} \\ &= \frac{\alpha(\alpha+1)(\alpha+2) \dots (\alpha+s-1) \beta(\beta+1)(\beta+2) \dots (\beta+n-s-1)}{(\alpha+\beta)(\alpha+\beta+1) \dots (\alpha+\beta+n-1)} \\ &= \frac{-\alpha(-\alpha-1)(-\alpha-2) \dots (-\alpha-s+1)(-\beta)(-\beta-1)(-\beta-2) \dots (-\beta-n+s+1)}{(-\alpha-\beta)(-\alpha-\beta-1) \dots (-\alpha-\beta-n+1)} \\ &= \frac{\binom{-\alpha}{s} \binom{-\beta}{n-s}}{\binom{-\alpha-\beta}{n}} \cdot \frac{s!(n-s)!}{n!} = \frac{\binom{-\alpha}{s} \binom{-\beta}{n-s}}{\binom{-\alpha-\beta}{n}} \cdot \frac{1}{\binom{n}{s}} = \mathbb{P}(Y_1 = y_1, \dots, Y_n = y_n) \end{aligned}$$

$$\mathbb{P}\left(\sum Y_i = s\right) = \frac{\binom{-\alpha}{s} \binom{-\beta}{n-s}}{\binom{-\alpha-\beta}{n}}$$

ROZKŁAD PREDYKCYJNY

$$\begin{aligned} f(1|y_1, \dots, y_n) &= \mathbb{P}(Y_{n+1} = 1|y_1, \dots, y_n) = \int_0^1 \mathbb{P}(Y_{n+1} = 1|\theta) \pi_{y_1, \dots, y_n}(\theta) d\theta \\ &= \int_0^1 \theta \pi_{y_1, \dots, y_n}(\theta) d\theta = \mathbb{E}(\Theta|y_1, \dots, y_n) = \frac{\alpha}{\alpha + \beta} (1-z) + \bar{y} \cdot z \end{aligned}$$

PRZYKŁAD LAPLACE'A

$Y_1, \dots, Y_n, Y_{n+1}$

$$\mathbb{P}(Y_1 = y_1, \dots, Y_n = y_n|\theta) = \theta^{\sum y_i} (1-\theta)^{n-\sum y_i}, \quad \text{gdzie } \theta = \frac{k}{m}$$

Rozkład *a priori*

$$\pi\left(\frac{k}{m}\right) = \mathbb{P}\left(\Theta = \frac{k}{m}\right) = \frac{1}{m+1}$$

$$z = \frac{n}{n + \alpha + \beta} = \frac{n}{n + 2}$$

$$\mathbb{P}(Y_{n+1} = 1 | Y_1 = \dots = Y_n = 1) = \frac{1}{2} \cdot \frac{2}{n+2} + 1 \cdot \frac{n}{n+2} = \frac{n+1}{n+2} \quad \text{w granicy}$$

09.11.2006r.

## Dostateczność.

$\mathcal{Y}$  – przestrzeń obserwacji

$\mathcal{P}$  – przestrzeń parametrów

$\{f_\theta\}$  – rodzina rozkładów prawdopodobieństwa na  $\mathcal{Y}$

$\pi$  – rozkład *a priori* na  $\mathcal{P}$


$$f_\theta(y) = f(y|\theta)$$

$$f(\theta, y) \stackrel{\text{df}}{=} f_\theta(y)\pi(\theta)$$

### Definicja 13.

STATYSTYKA jest to funkcja mierzalna

$$T : \mathcal{Y} \longrightarrow \mathcal{T}$$



### Przykład 13.

$$\mathcal{Y} = \mathbb{R}^n, \quad Y = (Y_1, \dots, Y_n)$$

$$\bar{Y} = \frac{1}{n} \sum_i Y_i$$

$$T : \mathbb{R}^n \longrightarrow \mathbb{R}$$

### Definicja 14.

Statystyka  $T$  jest DOSTATECZNA, jeśli dla każdego  $\theta$  rozkład warunkowy zmiennej  $Y$  przy danym  $T(Y) = t$  jest taki sam (nie zależy od  $\theta$ ).

$\mathcal{Y}$  i  $\mathcal{T}$  – przestrzenie dyskretne (założenie upraszczające)

### Definicja 15.

$T$  jest DOSTATECZNE, jeśli  $\mathbb{P}_\theta(Y = y | T(Y) = t)$  – nie zależy od  $\theta$

### Uwaga 8 (DOST).

$$\mathbb{P}_\theta(Y = y | T(Y) = t) = 0, \text{ jeśli } T(y) \neq t$$

rozkład warunkowy jest skupiony na  $\{y; T(y) = t\}$

**Uwaga 9.**

W modelu bayesowskim dostateczność można zapisać

$$\mathbb{P}(Y = y|T(Y) = t, \Theta = \theta) = \mathbb{P}(Y = y|T(Y) = t)$$

**Definicja 16 (FAKT).** KRYTERIUM FAKTORYZACJI

$T$  jest dostateczna, jeśli

$$f_{\theta}(y) = \mathbb{P}_{\theta}(Y = y) = \mathbb{P}(Y = y|\Theta = \theta)$$

daje się przedstawić jako  $h_{\theta}(T(y))g(y)$  (nie zależy od  $\theta$ )

**Definicja 17 (WN).**

Warunkowa niezależność

$$\mathbb{P}(Y = y, \Theta = \theta|T(Y) = t) = \mathbb{P}(Y = y|T(Y) = t)\mathbb{P}(\Theta = \theta|T(Y) = t)$$

UMOWA:  $T \stackrel{df}{=} T(Y)$

**Definicja 18 (BDOST).** BAYESOWSKA DOSTATECZNOŚĆ

$$\mathbb{P}(\Theta = \theta|Y = y) = \mathbb{P}(\Theta = \theta|T(Y) = T(y))$$

**Twierdzenie 2.**

DOST  $\Leftrightarrow$  FAKT  $\Leftrightarrow$  WN  $\Leftrightarrow$  BDOST

**Dowód.** DOST  $\Rightarrow$  FAKT

$$\begin{aligned} f_{\theta}(y) &= \mathbb{P}(Y = y|\Theta = \theta) = \mathbb{P}(Y = y, T = T(y)|\Theta = \theta) \\ &= \mathbb{P}(Y = y|T = T(y), \Theta = \theta)\mathbb{P}(T = T(y)|\Theta = \theta) \\ &\stackrel{DOST}{=} \mathbb{P}(Y = y|T = T(y))\mathbb{P}(T = T(y)|\Theta = \theta) \end{aligned}$$

FAKT  $\Rightarrow$  BDOST

$$\begin{aligned} \mathbb{P}(\Theta = \theta|Y = y) &= \frac{\mathbb{P}(Y = y|\Theta = \theta)\mathbb{P}(\Theta = \theta)}{\mathbb{P}(Y = y)} = \frac{h_{\theta}(T(y))g(y)\mathbb{P}(\Theta = \theta)}{\mathbb{P}(Y = y)} \\ &= \frac{h_{\theta}(T(y))g(y)\mathbb{P}(\Theta = \theta)}{\sum_{\theta'} h_{\theta'}(T(y))g(y)\mathbb{P}(\Theta = \theta')} = \mathbb{P}(\Theta = \theta|T = T(y)) \end{aligned}$$

$$\mathbb{P}(\Theta = \theta|Y = y, T = T(y)) = \mathbb{P}(\Theta = \theta|T = T(y))$$

WN  $\Leftrightarrow$  DOST  $\Leftrightarrow$  BDOST

□

**Przykład 14.**

MODEL BIN/BETA

$$Y_1, \dots, Y_n$$

$$f(1|\theta) = \mathbb{P}(Y_i = 1|\theta) = \theta, \quad \mathbb{P}(Y_i = 0|\theta) = 1 - \theta = f(0|\theta)$$

$Y_1, \dots, Y_n$  – warunkowo niezależne  $|\theta$

$$\pi(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

#### KRYTERIUM FAKTORYZACJI

$$f(y_1, \dots, y_n|\theta) \stackrel{WN}{=} f(y_1|\theta) \dots f(y_n|\theta) = \prod_{i=1}^n \left( \theta^{y_i} (1 - \theta)^{1-y_i} \right) = \theta^{\sum y_i} (1 - \theta)^{n - \sum y_i} \cdot 1$$

$S(y) = \sum y_i$  – jest statystyką dostateczną

#### ROZKŁAD WARUNKOWY

$(Y_1, \dots, Y_n)$  przy danym  $S(Y_1, \dots, Y_n) = \sum Y_i = s$

$$\begin{aligned} \mathbb{P}\left(Y_1 = y_1, \dots, Y_n = y_n \mid \sum Y_i = s\right) &= \begin{cases} 0 & \text{jeśli } \sum y_i \neq s \\ \frac{\mathbb{P}(Y_1=y_1, \dots, Y_n=y_n, S=s)}{\mathbb{P}(S=s)} & \text{jeśli } \sum y_i = s \end{cases} \\ &= \frac{\mathbb{P}(Y_1 = y_1, \dots, Y_n = y_n)}{\mathbb{P}(S = s)} = \frac{\theta^s (1 - \theta)^{n-s}}{\binom{n}{s} \theta^s (1 - \theta)^{n-s}} = \frac{1}{\binom{n}{s}} \end{aligned}$$

#### BDOST

$$\pi_y(\theta) = f(\theta|y_1, \dots, y_n) = \frac{f(y_1, \dots, y_n|\theta)\pi(\theta)}{f(y_1, \dots, y_n)} \propto \theta^{\sum y_i} (1 - \theta)^{n - \sum y_i} \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

$$f(\theta|y_1, \dots, y_n) = f(\theta|S = s) \quad \text{gdzie } s = \sum y_i$$

Jeśli  $f(y|\theta)$  i  $\pi(\theta)$  są gęstościami względem dowolnych miar  $\sigma$  - skończonych, to

$$\text{FAKT} \quad f(y|\theta) = h_\theta(T(y))g(y)$$

$$\text{WN} \quad f(y, \theta|t) = f(y|t)f(\theta|t)$$

$$\text{BDOST} \quad f(\theta|y) = f(\theta|t) \quad \text{gdzie } t = T(y)$$

15.11.2006r.

### Wykładnicze rodziny rozkładów prawdopodobieństwa.

$\mathcal{X}$  – przestrzeń obserwacji

$X$  – zmienna losowa (obserwacja) o gęstości  $f_\theta(x)$ ,  $x \in \mathcal{X}$ ,  $\theta \in \Theta$

#### Definicja 19.

Rodzina rozkładów prawdopodobieństwa na  $\mathcal{X}$  jest rodziną wykładniczą jeśli gęstości są postaci:

$$(*) \quad f_\theta(x) = \exp\left(\sum_{j=1}^k T_j(x)g_j(\theta) + g_0(\theta)\right)h(x), \quad \theta \in \Theta$$

**Przykład 15.**

Rodzina rozkładów  $U(0, \theta)$ ,  $\theta > 0$  nie jest rozkładem, wykładniczym (ponieważ zbiór na którym się zeruje ta gęstość zależy od  $\theta$ )

$$f_{\theta}(x) = \frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x)$$

**Przykład 16.**

$\{Ex(\theta) : \theta > 0\}$  jest rodziną wykładniczą,  $\mathcal{X} = [0, \infty)$

$$f_{\theta}(x) = \theta e^{-\theta x} = \exp(-\theta x + \log \theta)$$

**Przykład 17.**

$\{Poiiss(\theta) : \theta > 0\}$  jest rodziną wykładniczą,  $\mathcal{X} = \{0, 1, 2, \dots\}$

$$f_{\theta}(x) = e^{-\theta} \frac{\theta^x}{x!} = \exp\left(-\theta + x \log \theta\right) \frac{1}{x!}$$

**Przykład 18.**

$\{Gamma(\alpha, \lambda) : \alpha > 0, \lambda > 0\}$  jest rodziną wykładniczą,  $\mathcal{X} = [0, \infty)$ ,  $\theta = (\alpha, \lambda)$

$$f_{\alpha, \lambda}(x) = \frac{\lambda^{\alpha}}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} = \exp\left(-\lambda x + (\alpha - 1) \log x + \log \frac{\lambda^{\alpha}}{\Gamma(\alpha)}\right)$$

Jeżeli  $X_1, \dots, X_n$  jest próbką (iid)  $\sim f_{\theta}$ , to

$$f_{\theta}(x_1, \dots, x_n) = \prod_{i=1}^n f_{\theta}(x_i) = \exp\left\{\sum_{j=1}^k \left(\sum_{i=1}^n T_j(x_i)\right) g_j(\theta) + n g_0(\theta)\right\} \prod_{i=1}^n h(x_i)$$

Z kryterium faktoryzacji wynika, że

$$\left(\sum_{i=1}^n T_1(X_i), \dots, \sum_{i=1}^n T_k(X_i)\right) \quad - \text{ jest } k - \text{ wymiarową statystyką dostateczną}$$

gdzie  $n$  – rozmiar próbki

$k$  – ilość składników rodziny wykładniczej

**NATURALNA PARAMETRYZACJA RODZINY WYKŁADNICZEJ**

$$f_{\theta}(x) = \exp\left\{\sum_{j=1}^k T_j(x) \theta_j + \ell(\theta)\right\} h(x)$$

$$\ell(\theta) = -\log \int_{\mathcal{X}} \exp\left\{\sum_{j=1}^k T_j(x) \theta_j\right\} h(x) dx$$

$$\ell(\theta) = \ell(\theta_1, \dots, \theta_k)$$

**Stwierdzenie 1.**

$$\mathbb{E}_{\theta} T_j(X) = -\frac{\partial \ell(\theta)}{\partial \theta_j}$$

**Dowód.**

$$\begin{aligned} 0 &= \frac{\partial}{\partial \theta_j} \int_{\mathcal{X}} f_{\theta}(x) dx = \int_{\mathcal{X}} \frac{\partial}{\partial \theta_j} f_{\theta}(x) dx = \int_{\mathcal{X}} \left( T_j(x) + \frac{\partial \ell}{\partial \theta_j} \right) \exp \left( \sum_{r=1}^k T_r(x) \theta_r + \ell(\theta) \right) h(x) dx \\ &= \int_{\mathcal{X}} T_j(x) f_{\theta}(x) dx + \frac{\partial \ell}{\partial \theta_j} \int_{\mathcal{X}} f_{\theta}(x) dx = \mathbb{E}_{\theta} T_j(X) + \frac{\partial \ell}{\partial \theta_j} \end{aligned}$$

□

**Przykład 19.**

ROZKŁAD DWUMIANOWY,  $\text{Bin}(p, n)$ ,  $p \in (0, 1)$

$$\begin{aligned} f_p(x) &= \binom{n}{x} p^x (1-p)^{n-x} = \exp \left\{ x \log p + (n-x) \log(1-p) \right\} \binom{n}{x} \\ &= \exp \left\{ x \log \frac{p}{1-p} + n \log(1-p) \right\} \binom{n}{x} \end{aligned}$$

$$\theta = \log \frac{p}{1-p}$$

$$\ell(\theta) = n \log(1-p) = n \log \frac{1}{1+e^{\theta}}$$

$$\frac{\partial \ell}{\partial \theta} = -n \cdot \frac{e^{\theta}}{1+e^{\theta}} = -n \cdot p$$

**Definicja 20.**

Dla rodziny wykładniczej postaci (\*) rodzina gęstości

$$\pi(\theta) = \pi_{\alpha}(\theta) \propto \exp \left\{ \sum_{j=1}^k \alpha_j g_j(\theta) + \alpha_0 g_0(\theta) \right\}$$

nazywa się sprzężoną rodziną rozkładów *a priori*,  $\left( \alpha = (\alpha_0, \alpha_1, \dots, \alpha_k) \right)$

Założmy, że  $X_1, \dots, X_n$  są warunkowo *iid* (przy danym  $\theta$ ) o gęstości  $f_{\theta}$

**Stwierdzenie 2.**

Rozkład *a posteriori* ma postać

$$\begin{aligned} \pi(\theta|x_1) &\propto f_{\theta}(x_1) \pi(\theta) \propto \exp \left\{ \sum_{j=1}^k T_j(x) g_j(\theta) + g_0(\theta) \right\} \exp \left\{ \sum_{j=1}^k \alpha_j g_j(\theta) + \alpha_0 g_0(\theta) \right\} \\ &= \exp \left\{ \sum_{j=1}^k \left( \alpha_j + T_j(x) \right) g_j(\theta) + (\alpha_0 + 1) g_0(\theta) \right\} \end{aligned}$$

$$\pi(\theta|x_1, \dots, x_n) \propto f_{\theta}(x_1, \dots, x_n) \pi(\theta) \propto \exp \left\{ \sum_{j=1}^k \left( \alpha_j + \sum_{i=1}^n T_j(x_i) \right) g_j(\theta) + (\alpha_0 + n) g_0(\theta) \right\} = \pi_{\alpha}(\theta)$$

gdzie  $\alpha'_1 = \alpha_1 + \sum_{i=1}^n T_1(x_i)$

$$\begin{aligned} & \vdots \\ \alpha'_k &= \alpha_k + \sum_{i=1}^n T_k(x_i) \\ \alpha'_0 &= \alpha_0 + n \end{aligned}$$

**Przykład 20.** $\{Ex(\theta) : \theta > 0\}$ 

$$\begin{aligned} f_\theta(x) &= \theta e^{-\theta x} = \exp \left\{ -\theta x + \log \theta \right\} \\ f_\theta(x_1, \dots, x_n) &= \exp \left\{ -\theta \sum_{i=1}^n x_i + n \log \theta \right\} \end{aligned}$$

sprzężona rodzina rozkładów *a priori*

$$\pi_\alpha(\theta) = \pi_{\alpha_0, \alpha_1}(\theta) \propto \exp \left\{ -\theta \alpha_1 + \alpha_0 \log \theta \right\} = \theta^{\alpha_0} \exp \left\{ -\alpha_1 \cdot \theta \right\} = \mathcal{Gamma}(\alpha_0 + 1, \alpha_1)$$

Rozkład *a posteriori*  $\mathcal{Gamma}(\alpha_0 + n + 1, \alpha_1 + \sum x_i)$ 

16.11.2006r.

**Typowe modele bayesowskie ze sprzężonymi rodzinami rozkładów.**

BIN/BETA

 $X_1, \dots, X_n$ 

$$\mathbb{P}(X_i = 1|\theta) = \theta = f(1|\theta) \quad \theta \in (0, 1)$$

$$\mathbb{P}(X_i = 0|\theta) = 1 - \theta = f(0|\theta)$$

rozkład *a priori*

$$\pi(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1} \propto \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

$$\mathcal{U}(0, 1) = \mathcal{Beta}(1, 1)$$

rozkład *a posteriori*

$$\begin{aligned} f(\theta|x_1, \dots, x_n) &= \frac{f(x_1, \dots, x_n|\theta)\pi(\theta)}{f(x_1, \dots, x_n)} \propto \left( \prod_{i=1}^n f(x_i|\theta) \right) \pi(\theta) \\ &= \left( \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} \right) \pi(\theta) = \theta^{\sum x_i} (1 - \theta)^{n - \sum x_i} \theta^{\alpha-1} (1 - \theta)^{\beta-1} \\ &= \theta^{\sum x_i + \alpha - 1} (1 - \theta)^{n - \sum x_i + \beta - 1} \sim \mathcal{Beta}(\sum x_i + \alpha, n - \sum x_i + \beta) \end{aligned}$$

$$2 \text{ sukcesy i } 3 \text{ porażki} \quad \Rightarrow \quad \left. \mathcal{Beta}(\alpha + 2, 3 + \beta) \right\}_{\alpha, \beta = 1} \quad \mathcal{Beta}(3, 4)$$

$$\hat{\theta}_B = \mathbb{E}(\theta|x_1, \dots, x_n) = \frac{s + \alpha}{n + \alpha + \beta} - \text{estymator bayesowski parametru } \theta$$

$$\hat{\theta} = \frac{s}{n}$$

$$f_{\theta}(x) = \theta^x(1-\theta)^{1-x} = \exp \left\{ x \log \theta + (1-x) \log(1-\theta) \right\} = \exp \left\{ x \log \frac{\theta}{1-\theta} + \log(1-\theta) \right\}$$

$\sum x_i$  – statystyka dostateczna

Sprężona rodzina rozkładu *a priori*

$$\begin{aligned} \pi(\theta) &\propto \exp \left\{ \alpha_1 \log \frac{\theta}{1-\theta} + \alpha_0 \log(1-\theta) \right\} \\ &\propto \left( \frac{\theta}{1-\theta} \right)^{\alpha_1} (1-\theta)^{\alpha_0} = \theta^{\alpha_1} (1-\theta)^{\alpha_0 - \alpha_1} \sim \mathcal{Beta}(\alpha_1 + 1, \alpha_0 - \alpha_1 + 1) \end{aligned}$$

POISSON/GAMMA

$$f(k|\theta) = \mathbb{P}(X = k) = e^{-\theta} \frac{\theta^k}{k!}, \quad X \sim \text{Poisson}(\theta)$$

rozkład *a priori*

$$\pi(\theta) = \frac{\lambda^{\alpha}}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\lambda\theta} \propto \theta^{\alpha-1} e^{-\lambda\theta} \text{ rozkład } a \text{ posteriori}$$

$$\begin{aligned} f(\theta|x_1, \dots, x_n) &= \frac{f(x_1, \dots, x_n|\theta)\pi(\theta)}{f(x_1, \dots, x_n)} \propto \left( \prod_{i=1}^n f(x_i|\theta) \right) \pi(\theta) \\ &= \left( \prod_{i=1}^n \frac{\theta^{x_i}}{x_i!} e^{-\theta} \right) \theta^{\alpha-1} e^{-\lambda\theta} \propto \theta^{\sum x_i} \theta^{\alpha-1} e^{-\lambda\theta} e^{-n\theta} = \theta^{\sum x_i + \alpha - 1} e^{-(\lambda+n)\theta} \end{aligned}$$

$$\hat{\theta}_B = \mathbb{E}(\theta|X_1, \dots, X_n) = \frac{s + \alpha}{\lambda + n} \sim \mathcal{Gamma}(s + \alpha, \lambda + n), \quad \text{gdzie } s = \sum x_i$$

## 4. Funkcje straty, estymacja i predykcja bayesowska.

23.11.2006r.

### Teoria decyzji statystycznych.

$\mathcal{X}$  – przestrzeń obserwacji

$\mathcal{P}$  – przestrzeń parametrów

$\{\mathbb{P}_{\theta}; \theta \in \Theta\}$  – rodzina rozkładów prawdopodobieństwa na  $\mathcal{X}$

$X$  – obserwacja,  $X \sim \mathbb{P}_{\theta}$

$\mathcal{A}$  – przestrzeń akcji (decyzji),  $a \in \mathcal{A}$

### Definicja 21.

REGUŁA DECYZYJNA

$$\delta : \mathcal{X} \longrightarrow \mathcal{A}$$

„na podstawie (losowej) obserwacji  $X$  podejmujemy akcję (decyzję)  $\delta(X)$ ”



**Definicja 22.**

FUNKCJA STRAT

$$L : \mathcal{P} \times \mathcal{A} \longrightarrow \mathbb{R} \quad (\mathbb{R}_+)$$

$L(\theta, a)$  – strata jaką ponosi statystyk, jeśli podejmie akcję  $a$ , a wartością parametru jest  $\theta$

**GRA**

I gracz – Natura

II gracz – Statystyk

wybiera  $\theta \in \Theta$ wybiera  $a \in \mathcal{A}$ losujemy  $X \sim \mathbb{P}_\theta$  $a = \delta(X)$ 

1940 Abraham Wald

 $\mathbb{P}_\theta$  – ma gęstość  $f_\theta$ **Definicja 23.**

FUNKCJA RYZYKA

$$R(\theta, \delta) = \mathbb{E}_\theta L(\theta, \delta(X)) = \int_{\mathcal{X}} L(\theta, \delta(X)) f_\theta(x) dx$$

**Przykład 21** (estymacja). $\mathcal{P} \subseteq \mathbb{R}, \quad \mathcal{A} = \mathbb{R}$  $L(\theta, a) = (\theta - a)^2$  – kwadratowa funkcja straty $R(\theta, \delta) = \mathbb{E}_\theta (\theta - \delta(X))^2$       $\delta$  – estymator,  $\delta(X) \approx \hat{\theta}(X)$ **Przykład 22** (estymacja). $L(\theta, a) = |\theta - a|$  – błąd absolutny**Przykład 23** (estymacja). $\mathcal{P} = \mathbb{R}_+ = (0, \infty)$ 

$$L(\theta, a) = \frac{|\theta - a|}{\theta}$$

$$L(\theta, a) = \frac{(\theta - a)^2}{\theta^2}$$

**Przykład 24** (testowanie hipotez). $\mathcal{P} = \{\theta_0, \theta_1\}$  $H_0$  – hipoteza zerowa $H_1$  – hipoteza alternatywna $X \sim \mathcal{P}_\theta \quad \theta = \theta_0 \quad \text{lub} \quad \theta = \theta_1$  $\mathcal{A} = \{a_0, a_1\}$  $a_0$  – brak podstaw do odrzucenia  $H_0$

$a_1$  – odrzucamy  $H_0$  na rzecz  $H_1$

Rzut kostką

$$\mathcal{X} = \{1, 2, \dots, 6\}$$

$$\mathbb{P}_{\theta_0}$$

1	2	3	4	5	6
$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$

$$\mathbb{P}_{\theta_1}$$

1	2	3	4	5	6
$\frac{1}{6} - \frac{1}{100}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6} + \frac{1}{100}$

„dobra kostka”

„oszukana kostka”

$$L(\theta_0, a_0) = L(\theta_1, a_1) = 0$$

$$L(\theta_1, a_0) = L(\theta_0, a_1) = 1$$

$$\delta(x) = \begin{cases} a_1; & \text{jeśli } x = 6 \\ a_0; & \text{w p.p.} \end{cases}$$


1	2	3	4	5	6
$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$	$\frac{1}{6}$

– obszar krytyczny

$$R(\theta_0, \delta) = \mathbb{E}_{\theta_0} L(\theta_0, \delta(X)) = \mathbb{P}_{\theta_0}(\delta(X) = a_1) = \frac{1}{6} \quad \text{błąd I - go rodzaju}$$

$$R(\theta_1, \delta) = \mathbb{E}_{\theta_1} L(\theta_1, \delta(X)) = \mathbb{P}_{\theta_1}(\delta(X) = a_0) = \frac{5}{6} - \frac{1}{100} \quad \text{błąd II - go rodzaju}$$

decyzje statystyka	$a_0$	$a_1$
stan natury		
$H_0 : \theta_0$	O.K.	błąd I - szego rodzaju ozn. $\alpha$
$H_1 : \theta_1$	błąd II - go rodzaju ozn. $\beta$	O.K.



### Zadanie domowe 2.

Znaleźć funkcję ryzyka dla wszystkich reguł decyzyjnych.


**Przykład 25.**

$$X = (X_1, \dots, X_n) \stackrel{iid}{\sim} \mathcal{N}(\theta, 1)$$

$$L(\theta, a) = (\theta - a)^2$$

$$\bar{X} = \delta_1(X)$$

$$R(\theta, \delta_1) = \mathbb{E}_\theta(\theta - \bar{X})^2 = \text{Var}_\theta(\bar{X}) = \frac{1}{n}$$




Estymator bayesowski dla rozkładu *a priori*  $\theta \sim \mathcal{N}(m, a^2)$

$$\hat{\theta}_B = z\bar{X} + (1 - z)m$$

$$z = \frac{na^2}{na^2 + \delta^2} = \frac{na^2}{na^2 + 1}$$

$$\sigma^2 = 1$$



$$\delta_3(X) = m$$

$$R(\theta, \delta_3) = \mathbb{E}_\theta(\theta - m)^2 = (\theta - m)^2$$

**Definicja 24.**

RYZKO BAYESOWSKIE (dla rozkładu *a priori*  $\pi$ )

$$r(\delta) = r(\pi, \delta) = \mathbb{E} L(\Theta, \delta(X))$$


$$= \int_{\mathcal{P}} \int_{\mathcal{X}} L(\theta, \delta(x)) f_\theta(x) dx \pi(\theta) d\theta = \int_{\mathcal{P}} R(\theta, \delta) \pi(\theta) d\theta = \int_{\mathcal{P}} \mathbb{E} (L(\Theta, \delta(X)) | \Theta = \theta) \pi(\theta) d\theta$$

$$r(\delta) = \mathbb{E} \mathbb{E} (L(\Theta, \delta(X)) | X)$$

$$= \int_{\mathcal{X}} \underbrace{\mathbb{E} (L(\Theta, \delta(X)) | X = x)}_{\text{ryzyko a posteriori}} f(x) dx = \int_{\mathcal{X}} \underbrace{\int_{\mathcal{P}} L(\theta, \delta(x)) f(\theta|x) d\theta}_{\text{ryzyko a posteriori}} f(x) dx$$

gdzie  $f(\theta|x) = \frac{f_\theta(x)\pi(\theta)}{f(x)}$

[illegible]



## RYZYZKO

$$\begin{aligned} R_i &= \mathbb{E} [L(i, \delta(X)) | \theta = i] = \int_{\mathcal{X}} L(i, \delta(x)) f_i(x) dx \\ &= \sum_{j=0}^k \int_{D_j} L(i, j) f_i(x) dx = \sum_{j=0}^k L(i, j) \underbrace{\mathbb{P}(X \in D_j | \theta = i)}_{\int_{D_j} f_j(x) dx} \end{aligned}$$

## RYZYZKO BAYESOWSKIE

$$\begin{aligned} r &= \sum_{i=1}^k \pi_i R_i = \mathbb{E} L(\theta, \delta(X)) = \sum_{i=1}^k \sum_{j=0}^k \pi_i L(i, j) \mathbb{P}(X \in D_j | \theta = i) \\ r &= \int_{\mathcal{X}} \underbrace{\mathbb{E} [L(\Theta, \delta(X)) | X = x]}_{\text{ryzyko a posteriori}} f(x) dx \quad \text{gdzie} \quad f(x) = \sum_{i=1}^k \pi_i f_i(x) \\ r_x &= \sum_{i=1}^k \underbrace{L(i, \delta(x)) \mathbb{P}(\theta = i | X = x)}_{\text{rozkład a posteriori}} = \sum_{i=1}^k L(i, \delta(x)) \pi(i|x) \quad \text{gdzie} \quad \pi(i|x) = \frac{f_i(x) \pi_i}{f(x)} \end{aligned}$$

REGUŁA BAYESOWSKA  $\delta(x)$  dla ustalonego  $x$   $\delta^*(x) = j^*$ , jeśli

$$\sum_i L(i, j^*) \pi(i, x) \leq \sum_i L(i, j) \pi(i, x) \quad \forall_j$$

$$\Updownarrow$$

$$\sum_i L(i, j^*) f_i(x) \pi_i \leq \sum_i L(i, j) f_i(x) \pi_i \quad \forall_j$$

**Przykład 27.**

$$L(i, j) = \begin{cases} 0; & j = i \\ 1; & j \neq i \end{cases} \quad \mathcal{A} = \mathcal{P} = \{1, \dots, k\}$$

$r = \mathbb{P}(\theta \neq \delta(X))$  – prawdopodobieństwo błędnej klasyfikacji

Reguła bayesowska

$$\sum_i L(i, j) f_i(x) \pi_i = \sum_{i \neq j} f_i(x) \pi_i = f(x) - f_j(x) \pi_j \longrightarrow \min_j$$

$$\begin{aligned} \delta^*(x) &= j^* \text{ dla takiego } j^*, \text{ że} \\ f_{j^*}(x) \pi_{j^*} &\geq f_j(x) \pi_j \quad \forall_j \\ \pi(j^*|x) &\geq \pi(j|x) \quad \forall_j \end{aligned}$$

**Przykład 28.**

$$L(i, j) = \begin{cases} 0; & j = i \\ \lambda; & j = 0 \text{-- zawieszenie decyzji} \\ 1; & j \neq i \quad j \neq 0 \text{-- błędna klasyfikacja} \end{cases} \quad \lambda \in (0, 1)$$

$$\sum_i L(i, j) \pi(i|x) = \begin{cases} 1 - \pi(j|x); & \text{jeśli } j \neq 0 \\ \lambda; & \text{jeśli } j = 0 \end{cases}$$

Reguła bayesowska


Niech  $\pi(j^*|x) \geq \pi(j, x) \quad \forall_j$ 

$$\delta^*(x) = \begin{cases} j^*; & \text{jeśli } 1 - \pi(j^*|x) \leq \lambda \quad \pi(j^*) \geq 1 - \lambda \\ 0; & \text{jeśli } 1 - \pi(j^*|x) \geq \lambda \quad \pi(j^*) \leq 1 - \lambda \end{cases}$$

**Przykład 29.**

Dwa rozkłady normalne, d=1

$$f_i(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2\sigma^2}(x - \mu_i)^2\right) \quad i = 1, 2$$



Funkcja strat

	a=1	a=2	a=0
$\theta = 1$	0	$L(1, 2)$	$L(1, 0)$
$\theta = 2$	$L(2, 1)$	0	$L(2, 0)$

$$r_x = \sum_i L(i, j) \pi(i|x) = \begin{cases} L(2, 1) \pi(2|x); & j = 1 \\ L(1, 2) \pi(1|x); & j = 2 \\ L(1, 0) \pi(1|x) + L(2, 0) \pi(2|x); & j = 0 \end{cases}$$

 $1 \succ 0 :$ 

$$L(2, 1) \pi(2|x) \leq L(1, 0) \pi(1|x) + L(2, 0)$$

$$L(2, 1) f_2(x) \pi_2 \leq L(1, 0) f_1(x) \pi_1 + L(2, 0) f_2(x) \pi_2$$

$$L(2, 1) \frac{f_2}{f_1} \pi_2 \leq L(1, 0) \pi_1 + L(2, 0) \frac{f_2}{f_1} \pi_2$$

$$\frac{f_2}{f_1} [L(2, 1) - L(2, 0)] \pi_2 \leq L(1, 0) \pi_1$$

$$\delta^*(x) = 1 \quad \Leftrightarrow \quad \frac{f_2(x)}{f_1(x)} \leq \frac{\pi_1 L(1, 0)}{\pi_2 [L(2, 1) - L(2, 0)]} = c_1$$

$$\delta^*(x) = 2 \quad \Leftrightarrow \quad \frac{f_2(x)}{f_1(x)} \geq \frac{\pi_1 [L(1, 2) - L(1, 0)]}{\pi_2 L(2, 0)} = c_2$$

$$\delta^*(x) = 0 \quad \Leftrightarrow \quad c_1 \leq \frac{f_2(x)}{f_1(x)} \leq c_2$$

14.12.2006r.

**Zmienne losowe w  $\mathbb{R}^d$ .**

$$x = \begin{pmatrix} x_1 \\ \vdots \\ x_d \end{pmatrix} \in \mathbb{R}^d$$

 $f(x) = f(x_1, \dots, x_d)$  – gęstość rozkładu prawdopodobieństwa

$$X = (X_1, \dots, X_d)^T = \begin{pmatrix} X_1 \\ \vdots \\ X_d \end{pmatrix}$$

$$\mathbb{E} X = (\mathbb{E} X_1, \dots, \mathbb{E} X_d)^T = \mu$$

$$\begin{aligned} \text{Var } X &= \left( \text{Cov}(X_i, X_j) \right)_{i,j=1}^d = \mathbb{E} (X - \mu)(X - \mu)^T \\ &= \left( \mathbb{E} (X_i - \mu_i)(X_j - \mu_j) \right)_{i,j=1}^d \end{aligned}$$

**Twierdzenie 3.**

$$X \sim f_X, \quad h: \mathbb{R}^d \longrightarrow \mathbb{R}^d - \text{dyfeomorfizm}, \quad Y \stackrel{\text{df}}{=} h(X), \quad Dh^{-1} = \left( \frac{\partial h_i^{-1}(y)}{\partial y_j} \right)$$

Wtedy  $Y$  ma gęstość  $f_Y$ , gdzie

$$f_Y(y) = f_X(h^{-1}(y)) | \det Dh^{-1}(y) |$$

**5. Wielowymiarowe rozkłady normalne.**

$$Z = (Z_1, \dots, Z_d)^T, \quad \text{gdzie } Z_i \stackrel{iid}{\sim} \mathcal{N}(0, 1)$$

$$\mathbb{E} Z = 0$$

$$\text{Var } Z = I$$

$$Z \sim \mathcal{N}(0, I)$$

$$f_Z(z) = \prod_{i=1}^d \left( \frac{1}{\sqrt{2\pi}} \exp \left( -\frac{1}{2} z_i^2 \right) \right) = (2\pi)^{-\frac{d}{2}} \exp \left( -\frac{1}{2} \sum_{i=1}^d z_i^2 \right) = (2\pi)^{-\frac{d}{2}} \exp \left( -\frac{1}{2} z^T z \right)$$

$$x = h(z) = Rz - \text{przekształcenie liniowe}, \quad h: \mathbb{R}^d \longrightarrow \mathbb{R}^d, \quad h^{-1}(x) = R^{-1}x, \quad \det R \neq 0$$

nieosobliwe

$$f_X(x) = f_Z(z) \det R^{-1} = (2\pi)^{-\frac{d}{2}} \det R^{-1} \exp \left( -\frac{1}{2} x^T (R^{-1})^T (R^{-1}) x \right)$$

Ale

$$\text{Var } X = \mathbb{E} X X^T = \mathbb{E} R Z Z^T R^T = R (\mathbb{E} Z Z^T) R^T = R R^T = \Sigma, \quad \det \Sigma = (\det R)^2$$

Stąd

$$f_X(x) = (2\pi)^{-\frac{d}{2}} (\det \Sigma)^{-\frac{1}{2}} \exp \left( -\frac{1}{2} x^T \Sigma^{-1} x \right)$$

gdzie:  $\Sigma = \text{Var } X$ ,  $X \sim \mathcal{N}(0, \Sigma)$

$$Y \sim \mathcal{N}(\mu, \Sigma), \quad Y = X + \mu, \quad X \sim \mathcal{N}(0, \Sigma)$$

$$\mathbb{E} Y = \mu, \quad \text{Var } Y = \Sigma$$

$$f_Y(y) = (2\pi)^{-\frac{d}{2}} (\det \Sigma)^{-\frac{1}{2}} \exp \left( -\frac{1}{2} (y - \mu)^T \Sigma^{-1} (y - \mu) \right)$$

### Przykład 30.

Dyskryminacja dwóch rozkładów normalnych  $\pi_1, \pi_2 = 1 - \pi_1$  gdzie  $\pi_1$  – to prawdopodobieństwo, że obiekt pochodzi z pierwszej klasy

Jeśli  $i = 1$ , to  $X \sim \mathcal{N}(\mu_1, \Sigma_1)$

$i = 2$ , to  $X \sim \mathcal{N}(\mu_2, \Sigma_2)$

Funkcja straty  $L_{12}, L_{21}$   
 $L_{11} = L_{22} = 0$


Reguła bayesowska

$$\delta(x) = \begin{cases} 1; & \frac{f_2(x)}{f_1(x)} \leq \frac{\pi_1 L_{12}}{\pi_2 L_{21}} & \log \frac{f_2(x)}{f_1(x)} \leq \log \frac{\pi_1 L_{12}}{\pi_2 L_{21}} \\ 2; & \frac{f_2(x)}{f_1(x)} > \frac{\pi_1 L_{12}}{\pi_2 L_{21}} & \log \frac{f_2(x)}{f_1(x)} > \log \frac{\pi_1 L_{12}}{\pi_2 L_{21}} \end{cases}$$

$$\frac{f_2(x)}{f_1(x)} = \frac{1}{2} \left( \log \frac{\det \Sigma_1}{\det \Sigma_2} + (x - \mu_1)^T \Sigma_1^{-1} (x - \mu_1) - (x - \mu_2)^T \Sigma_2^{-1} (x - \mu_2) \right) \quad - \text{funkcja kwadratowa}$$

Obszary decyzyjne

$$D_i = \{x; \delta(x) = i\}$$




### Przykład 31.

Dwa rozkłady normalne  $\mathcal{N}(\mu_1, \Sigma), \mathcal{N}(\mu_2, \Sigma)$  z tą samą macierzą kowariancji.

$$\log \frac{f_2(x)}{f_1(x)} = \frac{1}{2} \left( (x - \mu_1)^T \Sigma^{-1} (x - \mu_1) - (x - \mu_2)^T \Sigma^{-1} (x - \mu_2) \right)$$





$$\pi_1 = \pi_2, \quad L_{12} = L_{21} \quad (\text{minimalizacja prawdopodobieństwa błędnej klasyfikacji})$$

$$\Sigma = I$$

$$\delta(x) = \begin{cases} 1; & \left(x - \frac{\mu_1 + \mu_2}{2}\right)^T (\mu_2 - \mu_1) < 0 \quad \Leftrightarrow \quad \|x - \mu_1\|^2 < \|x - \mu_2\|^2 \\ 2; & \|x - \mu_1\| > \|x - \mu_2\| \end{cases}$$

**Definicja 25.**

Odległość Mahalanobisa:  $\|x - y\|_\Sigma^2 = (x - y)^T \Sigma^{-1} (x - y)$

$$\delta(x) = \begin{cases} 1; & \|x - \mu_1\|_\Sigma < \|x - \mu_2\|_\Sigma \\ 2; & \|x - \mu_1\|_\Sigma > \|x - \mu_2\|_\Sigma \end{cases}$$

**Przykład 32.**

Dyskryminacja  $k$  rozkładów normalnych  $\mathcal{N}(\mu_1, \Sigma), \dots, \mathcal{N}(\mu_k, \Sigma)$  ze wspólną macierzą ko-

$$\text{wariancji } L_{i,j} = \begin{cases} 0; & i = j \\ 1; & i \neq j \end{cases}, \quad \pi_i = \frac{1}{k}$$


$$\delta(x) = i^*, \text{ jeśli } f_{i^*}(x) \geq f_i(x) \text{ dla wszystkich } i$$

$$\pi(i|x) = \frac{f_i(x)}{f(x)}$$

$$f(x) = \frac{1}{k} \sum_j f_j(x)$$

$$f_i(x) = (2\pi)^{-\frac{d}{2}} (\det \Sigma)^{-\frac{1}{2}} \exp \left( -\frac{1}{2} (x - \mu_i)^T \Sigma^{-1} (x - \mu_i) \right)$$

$$\delta(x) = i^* \quad \text{jeśli} \quad \|x - \mu_{i^*}\|_\Sigma \leq \|x - \mu_i\|_\Sigma$$



**Definicja 26.**

Niech  $(Y_1, \dots, Y_d)$  będzie zmienną losową o wartościach w  $\mathbb{R}^d$  taką, że  $\sum_{i=1}^d Y_i = 1$ , zaś  $(Y_1, \dots, Y_{d-1})$  mają gęstość

$$f_{\alpha_1, \dots, \alpha_d}(y_1, \dots, y_{d-1}) = \frac{\Gamma(\alpha_1 + \dots + \alpha_d)}{\Gamma(\alpha_1) \dots \Gamma(\alpha_d)} y_1^{\alpha_1-1} \dots y_{d-1}^{\alpha_{d-1}-1} (1 - y_1 - \dots - y_{d-1})^{\alpha_d-1}$$

$$\left( \text{dla } 0 \leq y_i, \quad \sum_{i=1}^{d-1} y_i \leq 1 \right)$$

Mówimy, że  $(Y_1, \dots, Y_d)$  ma ROZKŁAD DIRICHLETA  $\mathcal{D}(\alpha_1, \dots, \alpha_d)$ ,  $\alpha_i > 0$

**Definicja 27.**

$N_1, \dots, N_d$  ma ROZKŁAD WIELOMIANOWY  $\mathcal{M}(n, \theta_1, \dots, \theta_d)$ , jeśli

$$\mathbb{P}(N_1 = n_1, \dots, N_d = n_d) = \begin{cases} \frac{n!}{n_1! \dots n_d!} \theta_1^{n_1} \dots \theta_d^{n_d} & \text{jeśli } n_1 + \dots + n_d = n \\ 0 & \text{w p. p.} \end{cases}$$

**Uwaga 10.**

$$(N_1, N_2) \sim \mathcal{M}(n, \theta_1, \theta_2) \equiv N_1 \sim \mathcal{Bin}(n, \theta_1)$$

**Uwaga 11.**

$$(Y_1, Y_2) \sim \mathcal{D}(\alpha_1, \alpha_2) \equiv Y_1 \sim \mathcal{Be}(\alpha_1, \alpha_2)$$

**Stwierdzenie 3.**

Jeśli  $(N_1, \dots, N_d) \sim \mathcal{M}(n, \theta_1, \dots, \theta_d) | \theta_1, \dots, \theta_d$  warunkowo i  $(\theta_1, \dots, \theta_d)$  ma rozkład *a priori*  $\mathcal{D}(\alpha_1, \dots, \alpha_d)$ , to rozkład *a posteriori* jest  $\mathcal{D}(\alpha_1 + n_1, \dots, \alpha_d + n_d)$

**Dowód.**

$$\begin{aligned} \pi(\theta|n) &= \pi(\theta_1, \dots, \theta_{d-1} | n_1, \dots, n_d) \propto f(n|\theta) \pi(\theta) = f(n_1, \dots, n_d | \theta_1, \dots, \theta_{d-1}) \pi(\theta_1, \dots, \theta_{d-1}) \\ &= \theta_1^{n_1} \dots \theta_d^{n_d} \theta_1^{\alpha_1-1} \dots \theta_d^{\alpha_d-1} = \theta_1^{\alpha_1+n_1-1} \dots \theta_d^{\alpha_d+n_d-1}, \quad \text{gdzie } \theta_d = (1 - \theta_1 - \dots - \theta_{d-1}) \end{aligned}$$

□

ESTYMATORY BAYESOWSKIE PARAMETRÓW  $\theta_1, \dots, \theta_d$

$$\mathbb{E}(\theta_i) = \frac{\alpha_i}{\alpha_1 + \dots + \alpha_d} - a \text{ priori}$$

$$\mathbb{E}(\theta_i | n_1, \dots, n_d) = \frac{\alpha_i + n_i}{\alpha_1 + n_1 + \dots + \alpha_d + n_d} - a \text{ posteriori}$$

( $\alpha_i$  – pseudo-zliczenia)

NORMALNY/NORMALNY

$$X_1, \dots, X_n | \theta \stackrel{iid}{\sim} \mathcal{N}(\theta, \sigma^2) \quad \theta \sim \mathcal{N}(m, a^2)$$

$\sigma^2$  – znaneNORMALNY/ $\mathcal{IG}$ 

$$X_1, \dots, X_n | \nu \stackrel{iid}{\sim} \mathcal{N}(\mu, \frac{1}{\nu}) \quad \nu \sim \mathcal{Gamma}(\alpha, \lambda)$$

$$\mu - \text{znane} \quad \sigma^2 \sim \mathcal{IG}(\alpha, \lambda)$$

 $\nu = \frac{1}{\sigma^2}$  – „precyzja”

$$a \text{ posteriori} : \sigma^2 \sim \mathcal{IG}\left(\frac{n}{2} + \alpha, \lambda + \frac{1}{2} \sum (x_i - \mu)^2\right)$$

$$f(x_1, \dots, x_n | \nu) = \left(\frac{\nu^{\frac{1}{2}}}{\sqrt{2\pi}}\right)^n \exp\left\{-\frac{\nu}{2} \sum_{i=1}^n (x_i - \mu)^2\right\} \propto \nu^{\frac{n}{2}} \exp\left\{-\frac{\nu}{2} \sum_{i=1}^n (x_i - \mu)^2\right\}$$

gęstość *a priori*

$$\pi(\nu) = \frac{\lambda^\alpha}{\Gamma(\alpha)} \nu^{\alpha-1} e^{-\lambda\nu} \propto \nu^{\alpha-1} e^{-\lambda\nu}$$

gęstość *a posteriori*

$$\pi(\nu | x_1, \dots, x_n) \propto \nu^{\frac{n}{2} + \alpha - 1} \exp\left\{-\nu \left[\lambda + \frac{1}{2} \sum_{i=1}^n (x_i - \mu)^2\right]\right\}$$

**Definicja 28.**

$$Y \sim \mathcal{IG}(\alpha, \lambda) \equiv \frac{1}{Y} \sim \mathcal{Gamma}(\alpha, \lambda)$$

**Różne funkcje straty w zadaniach estymacji.** $\theta \in \mathcal{P} \subseteq \mathbb{R}$ Reguła decyzyjna  $\delta : \mathcal{X} \longrightarrow \mathbb{R}$ ,  $\delta(x)$  – estymator  $\theta$ 

1. Funkcja kwadratowa  $L(\theta, a) = (\theta - a)^2$   
 $\min_a \mathbb{E} (\theta - a)^2$ ,  $a_* = \mathbb{E} \theta$ ,  $\mathbb{E} (\theta - a_*)^2 = \text{Var}(\theta)$

Estymator bayesowski

$$\min_{\delta} \mathbb{E} [(\theta - \delta(X))^2 | X], \quad \delta^*(X) = \mathbb{E} (\theta | X)$$

$$\mathbb{E} [(\theta - \delta^*(X))^2 | X] = \text{Var}(\theta | X) - \text{ryzyko } a \text{ posteriori}$$

Ryzyko bayesowskie  $\mathbb{E} \text{Var}(\theta | X)$ 

2. Wartość bezwzględna błędu  $L(\theta, a) = |\theta - a|$

$$\min_a \mathbb{E} |\theta - a|, \quad a_* = \text{med}(\theta)$$

$$f(a) = |a|, \quad f'(a) = \text{sign}(a)$$

$$\frac{\partial}{\partial a} \mathbb{E} |\theta - a| = \mathbb{E} \frac{\partial}{\partial a} |\theta - a| = \mathbb{E} \frac{\partial}{\partial a} |a - \theta| = \mathbb{E} \text{sign}(a - \theta) = -\mathbb{P}(\theta > a) + \mathbb{P}(\theta < a) = 0$$

$$\mathbb{P}(\theta > a) = \mathbb{P}(\theta < a)$$

**Lemat 1.**

$$\mathbb{E} (\theta - a)_+ = \int_a^\infty \mathbb{P}(\theta > x) dx$$

**Lemat 2.**

$$\mathbb{E} |\theta - a| = \mathbb{E} (\theta - a)_+ + \mathbb{E} (a - \theta)_+ = \int_a^\infty \mathbb{P}(\theta > x) dx + \int_{-\infty}^a \mathbb{P}(\theta - x) dx$$

$$Q(a) = \int_a^\infty [1 - F(x)] dx + \int_{-\infty}^a F(x) dx$$

Jeżeli  $F$  jest ciągła w  $a$ , to

$$\frac{\partial}{\partial a} Q(a) = F(a) - [1 - F(a)] = 2F(a) - 1$$

Jeżeli  $F(a-) < F(a)$ , to

$$\begin{aligned} \frac{\partial}{\partial a-} Q(a) &= 2F(a-) - 1 \\ \frac{\partial}{\partial a+} Q(a) &= 2F(a) - 1 \end{aligned}$$

$$\frac{\partial}{\partial a-} Q(a) \leq 0 \leq \frac{\partial}{\partial a} Q(a)$$

**04.01.2007r.**

**Testowanie hipotez statystycznych.**

Przypadek dwóch hipotez prostych.

$\mathcal{X}$  – przestrzeń obserwacji

$\mathcal{P} = \{0, 1\}$  – przestrzeń parametrów

$$H_0 : \quad \theta = 0 \quad f(x|0) = f_0(x) \quad X \sim f_0$$

$$H_1 : \quad \theta = 1 \quad f(x|1) = f_1(x) \quad X \sim f_1$$

$\delta$  – reguła decyzyjna (test),  $\delta : \mathcal{X} \longrightarrow \mathcal{A} = \{0, 1\}$

0 – nie mamy podstaw do odrzucenia  $H_0$

1 – odrzucamy  $H_0$  na rzecz  $H_1$

$$\begin{aligned} \text{Funkcja straty} \quad L(0, 1) &= L(1, 0) = 1 \\ L(0, 0) &= L(1, 1) = 0 \end{aligned}$$

Rozkład *a priori*  $\pi_0, \pi_1 \quad \pi_0 + \pi_1 = 1, \quad \pi_i = \mathbb{P}(\Theta = i) \quad \text{dla } i = 1, 2$

$$\text{BŁĄD I rodzaju} \quad \mathbb{P}(\delta(X) = 1 | \Theta = 0) = \mathbb{P}_0(\delta(X) = 1) = \alpha(\delta) = \mathbb{E} \left( L(0, \delta(X)) | \Theta = 0 \right)$$

$$\text{II rodzaju} \quad \mathbb{P}(\delta(X) = 0 | \Theta = 1) = \mathbb{P}_1(\delta(X) = 0) = \beta(\delta) = \mathbb{E} \left( L(1, \delta(X)) | \Theta = 1 \right)$$


ZBIÓR RYZYKA

$$\mathcal{R} = \left\{ (\alpha(\delta), \beta(\delta)) : \delta \text{ jest testem} \right\}$$

**Przykład 33.**

$$\mathcal{X} = \{1, 2, 3\}$$

$x$	1	2	3
$f_1$	$\frac{1}{6}$	$\frac{2}{6}$	$\frac{3}{6}$
$f_0$	$\frac{3}{6}$	$\frac{2}{6}$	$\frac{1}{6}$
$\frac{f_1}{f_0}$	$\frac{1}{3}$	1	3



Reguły bayesowskie przy wszystkich możliwych rozkładach *a priori*

$$\delta(x) = \begin{cases} 1, & \text{jeśli } \frac{f_1(x)}{f_0(x)} > \frac{\pi_0}{\pi_1} = c \\ 1 \text{ lub } 0 & \text{jeśli } \frac{f_1(x)}{f_0(x)} = \frac{\pi_0}{\pi_1} \\ 0, & \text{jeśli } \frac{f_1(x)}{f_0(x)} < \frac{\pi_0}{\pi_1} = c \end{cases} \quad \text{test ilorazu wiarygodności}$$

$$\delta' = 1 - \delta$$

$$\alpha(\delta') = 1 - \alpha(\delta)$$

$$\beta(\delta') = 1 - \beta(\delta)$$

**Definicja 29.**

$\delta^*$  jest **najmocniejszym** testem **na poziomie istotności  $\alpha^*$** , jeśli

1.  $\alpha(\delta^*) \leq \alpha^*$
2. Jeśli  $\alpha(\delta^*) \leq \alpha^*$ , to  $\beta(\delta^*) \leq \beta(\delta)$

**Lemat 3** (Neymana – Pearsona). Jeżeli  $\delta^*$  jest najmocniejszym testem na poziomie istotności  $\alpha^* \in (0, 1)$  i  $\alpha(\delta^*) = \alpha^*$ , to istnieje  $c \in [0, \infty)$  takie, że

$$\delta^*(x) = \begin{cases} 1, & \text{jeśli } \frac{f_1(x)}{f_0(x)} > c \\ 0, & \text{jeśli } \frac{f_1(x)}{f_0(x)} < c \end{cases} \quad (*)$$

Jeżeli  $\delta^*$  spełnia (\*) i  $\alpha(\delta^*) = \alpha^*$ , to  $\delta^*$  jest najmocniejszy na poziomie istotności  $\alpha^*$ .

**Przykład 34.**

$$\mathcal{X} = [0, 1] \quad f_0(x) = 1 \quad f_1(x) = 2x \frac{f_1(x)}{f_0(x)} = 2x$$

$$\alpha(\delta) = \mathbb{P}_0(2X > c) = \mathbb{P}_0(X > \frac{c}{2}) = 1 - \frac{c}{2}$$

$$\beta(\delta) = \mathbb{P}_1(2X \leq c) = \mathbb{P}_1(X \leq \frac{c}{2}) = \left(\frac{c}{2}\right)^2$$

$$\beta(\alpha) = (1 - \alpha)^2$$

Najmocniejszy test na poziomie istotności  $\alpha^* = 0.005$

$$\alpha = 0.005$$

$$\beta = (1 - \alpha)^2 = (0.995)^2$$

TEST ZRANDOMIZOWANY  $\delta : \mathcal{X} \longrightarrow [0, 1]$

$\delta(x)$  – prawdopodobieństwo podjęcia decyzji 1, (odrzuć hipotezę  $H_0$ )

Zbiór ryzyka dla reguł zrandomizowanych jest wypukły.

$$\delta_1 \quad (\alpha(\delta_1), \beta(\delta_1))$$

$$\delta_2 \quad (\alpha(\delta_2), \beta(\delta_2))$$

$$\delta = \lambda\delta_1 + (1 - \lambda)\delta_2$$


$$\alpha(\delta) = \int_{\mathcal{X}} \delta(x) f_0(x) dx$$

$$\beta(\delta) = \int_{\mathcal{X}} (1 - \delta(x)) f_1(x) dx$$

**Przykład (33 c. d.).** Najmocniejszy test niezrandomizowany na poziomie istotności  $\alpha^* = 0.05$  jest  $\delta(x) \equiv 0$  (nigdy nie odrzucamy).

Najmocniejszy test zrandomizowany na poziomie istotności  $\alpha^* = 0.05$  jest  $\delta(x) \equiv 0$ .

$$\delta(x) = \begin{cases} 0, & \text{jeśli } x = 1 \text{ lub } x = 2 \\ \frac{\frac{1}{20}}{\frac{1}{6}} = \frac{6}{20} = \frac{3}{10}, & \text{jeśli } x = 3 \end{cases}$$



11.01.2007r.

**Krzywa  $(\alpha - \beta)$  Neymana – Pearsona.**

$$H_0 : \theta = 0 \quad f_0$$

$$h = \frac{f_1}{f_0}$$

$$H_1: \quad \theta = 1 \quad f_1$$

Testy ilorazu wiarygodności:

$$\delta(x) = \begin{cases} 1; & \text{jeśli } h(x) > c \\ \varrho; & \text{jeśli } h(x) = c \\ 0; & \text{jeśli } h(x) < c \end{cases}$$

dokładniej, jeśli  $h(x) = c$ , to bierzemy

$$\delta(x) = \begin{cases} 1; & \text{z prawdopodobieństwem } \varrho \\ 0; & \text{z prawdopodobieństwem } 1 - \varrho \end{cases}$$

$$\alpha(c, \varrho) = \int_{\{h > c\}} f_0 + \varrho \int_{\{h = c\}} f_0$$

$$\beta(c, \varrho) = \int_{\{h < c\}} f_1 + (1 - \varrho) \int_{\{h = c\}} f_1$$

$$F_0(c) = \mathbb{P}_0(h \leq c) = \int_{\{h \leq c\}} f_0$$

$$F_1(c) = \mathbb{P}_1(h \leq c) = \int_{\{h \leq c\}} f_1$$

$$\alpha(c, \varrho) = 1 - F_0(c) + \varrho[F_0(c) - F_0(c-)] = \mathbb{E}_0 \frac{f_1}{f_0} \mathbb{1}(h \leq c)$$

$$\beta(c, \varrho) = F_1(c-) + (1 - \varrho)[F_1(c) - F_1(c-)] = \mathbb{E}_0 h \mathbb{1}(h \leq c)$$

## Testowanie hipotez złożonych w ujęciu bayesowskim.

$\mathcal{P}$  – przestrzeń parametrów

$\mathcal{X}$  – przestrzeń obserwacji

$f(x|\theta)$  – wiarygodność

$\pi(\theta)$  – *a priori*

$\pi(\theta|x)$  – *a posteriori*

$$H_0: \quad \theta \in \mathcal{P}_0 \subset \mathcal{P} \quad \mathcal{P}_0 \cap \mathcal{P}_1 = \emptyset$$

$$H_1: \quad \theta \in \mathcal{P}_1 \subset \mathcal{P} \quad \mathcal{P}_1 = \mathcal{P} \setminus \mathcal{P}_0$$

$$\mathbb{P}(H_0|X = x) = \mathbb{P}(\theta \in \mathcal{P}_0|X = x) = \int_{\mathcal{P}_0} \pi(\theta|x) d\theta$$

$$\mathbb{P}(H_1|X = x) = \mathbb{P}(\theta \in \mathcal{P}_1|X = x) = \int_{\mathcal{P}_1} \pi(\theta|x) d\theta$$

**Przykład 35.**

$$X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\theta, \sigma^2) \quad H_0 : \theta \leq \theta_0$$

$$H_1 : \theta > \theta_0$$

$$a \text{ priori} \quad \theta \sim \mathcal{N}(m, a^2)$$

$$a \text{ posteriori} \quad \theta \sim \mathcal{N}\left(z\bar{x} + (1-z)m, \frac{a^2\sigma^2}{na^2 + \sigma^2}\right) \quad z = \frac{na^2}{na^2 + \sigma^2}$$


$$\begin{aligned} \mathbb{P}(H_0 | x_1, \dots, x_n) &= \int_{-\infty}^{\theta_0} \pi(\theta | x_1, \dots, x_n) d\theta = \mathbb{P}(\theta \leq \theta_0 | x_1, \dots, x_n) \\ &= \mathbb{P}\left(\frac{\theta - 2\bar{x} - (1-z)m}{a\sigma} \sqrt{na^2 + \sigma^2} \leq \frac{\theta_0 - 2\bar{x} - (1-z)m}{a\sigma} \sqrt{na^2 + \sigma^2}\right) \\ &= \Phi\left(\frac{\theta_0 - 2\bar{x} - (1-z)m}{a\sigma} \sqrt{na^2 + \sigma^2}\right) \end{aligned}$$

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta \neq \theta_0$$

Rozkład *a priori*

$$\mathbb{P}(\theta = \theta_0) = c, \quad c \in (0, 1)$$

**Zbiory (przedziały ufności) w ujęciu bayesowskim.**

$$\mathcal{P} \quad \mathcal{X}$$

$$\pi \quad f$$

**Definicja 30.**

Przyporządkowanie  $x \mapsto C(x) \subset \mathcal{P}$

$$\mathbb{P}(\theta \in C(x) | X) = 1 - \alpha$$

nazywamy PRZEDZIAŁEM UFNOŚCI na poziomie  $1 - \alpha$

**Uwaga 12.**

W statystyce klasycznej

$$\mathbb{P}(\theta \in C(x) | \theta) = 1 - \alpha$$



**Stwierdzenie 4.**

Założmy, że  $\pi$  jest gęstością względem miary Lebesgue'a.

$\pi(\cdot|x)$  też jest gęstością względem miary Lebesgue'a.

Jeżeli istnieje takie  $c \in (0, \infty)$ , że

$$\mathbb{P}(\pi(\theta|x) > c|x) = \int_{\{\theta; \pi(\theta|x) > c\}} \pi(\theta|x) d\theta = 1 - \alpha$$

to  $C^*(x) = \{\theta; \pi(\theta|x) > c\}$  jest najmniejszym w sensie miary Lebesgue'a przedziałem ufności na poziomie  $1 - \alpha$

**Dowód.**  $x \in \mathcal{X}$  – ustalone

Jeżeli  $\int_{C(x)} \pi(x|\theta) d\theta = 1 - \alpha$ , to  $|C(x)| \geq |C^*(x)|$

$$C(x) = C$$

$$C^*(x) = C^*$$


$$\pi(\theta|x) = \pi(\theta)$$

$$\int_C \pi = 1 - \alpha = \int_C^* \pi$$

na  $C^*$  mamy  $\pi > c$

poza  $C^*$  mamy  $\pi \leq c$

$$c |C \setminus C^*| \geq \int_{C \setminus C^*} \pi = \int_{C^* \setminus C} \pi > \int_{C^* \setminus C} c = c |C^* \setminus C|$$



$$|C \setminus C^*| > |C^* \setminus C|$$

$$|C| > |C^*| \quad \text{jeśli} \quad |C \setminus C^*| > 0$$

□

**Predykcja liniowa i liniowe modele bayesowskie.**

$\theta$  – jednowymiarowa zmienna losowa,  $X$

Znaleźć funkcję  $\delta : \mathcal{X} \rightarrow \mathbb{R}$  taką, żeby  $\mathbb{E} (\delta(X) - \theta)^2$  była minimalna

$$\delta^*(X) = \mathbb{E}(\theta|X) \quad - \quad \text{rozwiązanie}$$

**Twierdzenie 4.**

Jeżeli  $\theta, X_1, \dots, X_n$  są zmiennymi losowymi  $X = (X_1, \dots, X_n)^T$ , to funkcja liniowa

$$\delta(x) = \delta(X_1, \dots, X_n) = c_0 + \sum_{i=1}^n c_i X_i = c_0 + c^T X$$

minimalizująca  $\mathbb{E} (\theta - \delta(X))^2$  jest dana wzorami

$$c_* = \text{Var}(X)^{-1} \text{Cov}(X, \theta)$$

$$c_0 = \mathbb{E} \theta - c_*^T \mathbb{E} X$$

gdzie

$$\begin{aligned} \text{Var}(X) &= \left( \text{Cov}(X_i, X_j); i, j = 1, \dots, n \right) \\ \text{Cov}(X, \theta) &= \left( \text{Cov}(X_i, \theta); i = 1, \dots, n \right) \end{aligned}$$

18.01.2007r.

### Empiryczne metody bayesowskie i hierarchiczne modele bayesowskie.

#### Przykład 36 (NORMALNY/NORMALNY).

$$X_1, \dots, X_n \stackrel{iid}{\sim} \mathcal{N}(\theta, s^2), \quad \theta \sim \mathcal{N}(m, a^2)$$

$$a \text{ posteriori} \quad \theta \sim \mathcal{N}\left(z\bar{X} + (1-z)m, \frac{a^2 s^2}{na^2 + s^2}\right), \quad \text{gdzie: } z = \frac{na^2}{na^2 + s^2}$$

$$\hat{\theta}_B = z\bar{X} + (1-z)m$$

#### INTERPRETACJA UBEZPIECZENIOWA.

$\theta; X_1, \dots, X_n$  – sumaryczne szkody zgłoszone przez klienta w poszczególnych latach  $1, 2, \dots, n$


$\theta = \mathbb{E}(X_i|\theta)$  – średnia wartość szkód dla naszego klienta

$s^2 = \text{Var}(X_i|\theta)$  – zmienność pomiędzy latami

$m$  – średnia szkoda w całej populacji klientów

$a^2$  – zmienność w populacji klientów

#### MODEL UWZGLĘDNIAJĄCY PRÓBKĘ Z POPULACJI KLIENTÓW



$X_{ji}$  – szkody  $j$ -tego klienta w  $i$ -tym roku,  $j = 1, \dots, p \quad i = 1, \dots, n$

$$X_{ji} \sim \mathcal{N}(\theta_j, s^2), \quad \theta_1, \dots, \theta_p \stackrel{iid}{\sim} \mathcal{N}(m, a^2)$$

Łączny rozkład prawdopodobieństwa

$$f((\theta_j), (x_{ji})) = \prod_{j=1}^p \pi(\theta_j) \prod_{i=1}^n f(x_{ji}|\theta_j)$$

## EMPIRYCZNE PODEJŚCIE BAYESOWSKIE

Estymujemy rozkład *a priori* parametru  $\theta$  na podstawie próbek odpowiadających różnym „realizacjom” zmiennej losowej  $\theta$ .

$$\begin{array}{l} \theta_1 \quad ; \quad X_{11} \quad \dots \quad X_{1n} \\ \vdots \\ \theta_j \quad ; \quad X_{j1} \quad \dots \quad X_{jn} \quad \leftarrow \quad \text{Dane} \\ \vdots \\ \theta_p \quad ; \quad X_{p1} \quad \dots \quad X_{pn} \end{array}$$

1. Na podstawie całej tablicy estymujemy parametry rozkładu *a priori*  $m, a^2$  (i parametr  $s^2$ ).
2. W rozwiązaniach bayesowskich wstawiamy wyestymowany rozkład *a priori*.

Ad. 1.

$$\left. \begin{array}{l} \widehat{m} = \bar{X} = \frac{1}{np} \sum_{j=1}^p \sum_{i=1}^n X_{ji} = \frac{1}{p} \sum_{j=1}^p \bar{X}_j ; \quad \text{gdzie} \quad \bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ji} \\ \widehat{s}^2 = \frac{1}{p} \sum_{j=1}^p \frac{1}{n-1} \sum_{i=1}^n (X_{ji} - \bar{X}_j)^2 ; \quad \text{gdzie} \quad \bar{X}_j = \frac{1}{n} \sum_{i=1}^n X_{ji} \\ \widehat{a}^2 = \frac{1}{p-1} \sum_{j=1}^p (\bar{X}_j - \bar{X})^2 - \frac{1}{n} \widehat{s}^2 \end{array} \right\} \text{estymatory nieobciążone}$$

Ad. 2. Estymator bayesowski parametru  $\theta_j$

$$\widehat{\theta}_j^B = z \bar{X}_j + (1-z)m$$

Estymator empiryczny bayesowski

$$\widehat{\theta}_j^{EB} = \widehat{z} \bar{X}_j + (1-\widehat{z})\widehat{m} \quad \text{gdzie} \quad \widehat{z} = \frac{n\widehat{a}^2}{n\widehat{a}^2 + \widehat{s}^2}$$

## HIERARCHICZNY MODEL BAYESOWSKI.

$$\begin{array}{ll} X_{ji} \stackrel{iid}{\sim} \mathcal{N}(\theta_j, s^2) & \theta_j \stackrel{iid}{\sim} \mathcal{N}(m, a^2) \\ s^2 \sim \mathcal{IG}(p, c) & m \sim \mathcal{N}(\nu, b^2) \\ & a^2 \sim \mathcal{IG}(q, d) \end{array}$$

$$\tau = \frac{1}{s^2} \sim \mathcal{Gamma}(p, c)$$

$$\zeta = \frac{1}{a^2} \sim \mathcal{Gamma}(q, d)$$

Znane:  $\nu, b^2, p, c, q, d$

Parametry losowe:  $s^2, a^2, m, \theta_1, \dots, \theta_q$

Łączny rozkład

$$f((x_{ji}), (\theta_j), m, \tau, \zeta) = h(\zeta)g(\tau)\varphi(m) \prod_j \pi(\theta_j|m, \zeta) \prod_i f(x_{ji}|\theta_j, \tau)$$

Cel: estymacja bayesowska  $\theta_j$

## PRÓBNIK GIBSA.

Rozważmy zmienną losową  $\theta = (\theta_1, \dots, \theta_k)$  o wartościach w przestrzeni  $\mathcal{X}^k$  i gęstości  $\pi(\theta_1, \dots, \theta_k)$

Umiemy losować zmienne losowe jednowymiarowe z gęstości warunkowych

$$\pi(\theta_i | \theta_1, \dots, \theta_{i-1}, \theta_{i+1}, \dots, \theta_k)$$

Generujemy ciąg wektorów losowych  $\theta(0), \theta(1), \dots, \theta(n), \dots$

Jeżeli  $\theta(n) = (\theta_1, \dots, \theta_k) \stackrel{\text{ozn}}{=} \theta$ , to  $\theta(n+1) = (\theta'_1, \dots, \theta'_k) = \theta'$  losujemy w  $k$  krokach

1.  $\theta'_1 \sim \pi(\cdot | \theta_2, \dots, \theta_k)$
2.  $\theta'_2 \sim \pi(\cdot | \theta'_1, \theta_3, \dots, \theta_k)$
- $\vdots$
- k-1.  $\theta'_{k-1} \sim \pi(\cdot | \theta'_1, \dots, \theta'_{k-2}, \theta_k)$
- k.  $\theta'_k \sim \pi(\cdot | \theta'_1, \dots, \theta'_{k-1})$

Przy pewnych założeniach na rozkład  $\pi$

$$\begin{aligned} \theta(n) &\xrightarrow[n \rightarrow \infty]{} \pi \\ \frac{1}{n} \sum_{t=1}^n h(\theta(t)) &\xrightarrow[n \rightarrow \infty]{} \int_{\mathcal{X}^n} h(\theta) \pi(\theta) d\theta = \mathbb{E}_{\pi} h(\theta) \end{aligned}$$